Notes de Cours d'Inférence Statistique

Yehor KOROTENKO

07 March 2026

Table des matieres

1 Introduction **3**
1.1 Evaluation 3
1.2 Modèle Statistique 3
1.3 Estimateurs 3
1.4 Risque quadratique 4
1.4.1 Exemple : Modèle de Poisson 4
1.5 Consistance 5
1.5.1 Exemple : Retour au modèle de Poisson 5
1.5.2 Méthode « Plug-in » 5

2 Estimateurs **6**
2.1 Cadre paramétrique 6
2.1.1 Modèle statistique paramétrique 6
2.2 Méthode des moments 6
2.3 Rendu sur le L.A.C. 8
2.3.1 Variance empirique 9
2.4 Méthode de maximum de vraisemblance 9
2.4.1 Modèle donné 9
2.4.2 En pratique 9

3 Information de Fisher, efficacité **12**
3.1 Modèle régulier 12
3.2 Score et Information de Fisher 13
3.3 Information de Fisher et derivée seconde 15
3.4 Inégalité de Cramer - Rao 15

4 Étude asymptotique des estimateurs **17**
4.1 Convergences 17
4.2 Consistance des estimateurs 18
4.3 Normalité asymptotique 18
4.4 δ-méthode 20

5 Fonction de répartition empirique **21**
5.1 Estimation empirique 22
5.2 Inverse généralisé 22
5.3 Quantile empirique 24

6 Intervalles de confiance **25**
6.1 Définitions 25

6.2 Interprétation 25
6.3 Méthode pivotale 25

7 Compléments (avant partiel) 27
7.1 Propriétés asymptotiques d'une suite d'estimateurs $\left(\hat{\theta}_n\right)_{n\geq 1}$ 27
7.2 Pivot (asymptotique) ou statistique pivotale 29

Introduction

§1

1.1 Evaluation

- 0.4 CC +0.6 Examen.
- Répartition : 80% partiel, 20% Interro (prévue le 26/01).

1.2 Modèle Statistique

Definition 1.1 (Modèle Statistique) – *Un modèle statistique est un espace de probabilité $(\Omega, \mathcal{A}, \mathcal{P})$ où $\mathcal{P}$ est une famille de lois de probabilité $\{P_\theta; \theta \in \Theta\}$.*

- Si $\exists p \in \mathbb{N}^*, \Theta \subset \mathbb{R}^p$: modèle paramétrique.
- Sinon : modèle non paramétrique.

Exemple 1.2 (Familles de lois) –

- *Lois de Poisson :* $\mathcal{P} = \{P(\lambda); \lambda > 0\}$.
- *Densité régulière :* $\mathcal{P} = \{\mathbb{P}; \mathbb{P}$ dont la densité admet une dérivée seconde bornée$\}$.

◇

Definition 1.3 (Observation) – *Une observation est une variable aléatoire (v.a.) dont la loi appartient à $\{P_\theta, \theta \in \Theta\}$. Notre observation aura une structure de n-échantillons $X_1, ..., X_n$ i.i.d. (indépendants et identiquement distribués) de loi commune $\in \{P_\theta, \theta \in \Theta\}$.*

Remarque 1.4 – *$(X_1, ..., X_n)$ est de loi $P_\theta^{\otimes n}$. L'échantillon contient toute l'information sur P_θ, donc sur θ.* ◇

Definition 1.5 (Identifiabilité) – *Un modèle est identifiable si et seulement si (ssi) l'application $\theta \mapsto P_\theta$ est injective.*

1.3 Estimateurs

Hypothèse : On observe $X_1, ..., X_n$ i.i.d. de loi commune $\in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$ (modèle paramétrique identifiable). Soit θ^* la vraie valeur inconnue telle que $P_{X_i} = P_{\theta^*}$.

Definition 1.6 (Estimateur) – *Un estimateur de θ est une fonction de l'échantillon $(X_1, ..., X_n)$ mesurable et indépendante de θ (calculable à partir des données).*

Notation : $\hat{\theta} = \hat{\theta}_n = h(X_1, ..., X_n)$. C'est une variable aléatoire.
Exemples : $\hat{\theta} = \overline{X}$, $\hat{\theta} = X_1 - X_3$, etc.

Questions fondamentales :

1. Comment définir un bon estimateur ?
2. Comment construire un bon estimateur ?

1.4 Risque quadratique

Idée : En moyenne, $\hat{\theta}$ doit être proche de θ. On regarde $\mathbb{E}\left[\hat{\theta} - \theta\right]$.

Definition 1.7 (Biais) – *Le biais de $\hat{\theta}$ est défini par :*

$$B\left(\hat{\theta}, \theta\right) = \mathbb{E}\left[\hat{\theta}\right] - \theta$$

*On dit que $\hat{\theta}$ est **sans biais** si $B\left(\hat{\theta}, \theta\right) = 0$.*

Definition 1.8 (Risque quadratique / MSE) –

$$R\left(\hat{\theta}, \theta\right) = \mathbb{E}\left[\left(\hat{\theta} - \theta\right)^2\right]$$

*C'est la **Mean Squared Error (MSE)** en anglais.*

On dit que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ ssi $R\left(\hat{\theta}_1, \theta\right) \leq R\left(\hat{\theta}_2, \theta\right)$.

1.4.1 Exemple : Modèle de Poisson

Soit $X_1, ..., X_n$ de loi P_θ de Poisson, $\theta > 0$. On cherche un estimateur de $\theta = \mathbb{E}[X_i]$.

Proposons : $\hat{\theta} = \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$.

Calcul du Biais :

$$\begin{aligned}
B\left(\hat{\theta}, \theta\right) &= \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] - \theta \\
&= \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}[X_i] - \theta \quad \text{(par linéarité)} \\
&= \frac{1}{n} \cdot n \cdot \mathbb{E}[X_1] - \theta \\
&= \theta - \theta = 0
\end{aligned}$$

Donc $\mathbb{E}\left[\overline{X}\right] = \theta$, est l'estimateur sans biais.

Calcul du Risque :

$$\begin{aligned}
R\left(\hat{\theta}, \theta\right) &= \mathbb{E}\left[\left(\overline{X} - \theta\right)^2\right] = \mathbb{E}\left[\left(\overline{X} - \mathbb{E}\left[\overline{X}\right]\right)^2\right] \\
&= \mathrm{Var}\left(\overline{X}\right) = \mathrm{Var}\left(\frac{1}{n}\sum X_i\right) \\
&= \frac{1}{n^2}\sum \mathrm{Var}(X_i) \quad \text{(car i.i.d)} \\
&= \frac{1}{n^2} \cdot n \cdot \mathrm{Var}(X_1) = \frac{\mathrm{Var}(X_1)}{n} = \frac{\theta}{n}
\end{aligned}$$

Theoreme 1.9 (Décomposition Biais-Variance du risque) –

$$R\left(\hat{\theta}, \theta\right) = \left(B\left(\hat{\theta}, \theta\right)\right)^2 + \mathrm{Var}\left(\hat{\theta}\right)$$

Preuve.

$$
\begin{aligned}
R\left(\hat{\theta},\theta\right) &= \mathbb{E}\left[\left(\hat{\theta}-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}\left[\hat{\theta}\right]+\mathbb{E}\left[\hat{\theta}\right]-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}\left[\hat{\theta}\right]\right)^2\right]+\mathbb{E}\left[\left(\mathbb{E}\left[\hat{\theta}\right]-\theta\right)^2\right]+2\mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}\left[\hat{\theta}\right]\right)\left(\mathbb{E}\left[\hat{\theta}\right]-\theta\right)\right] \\
&= \mathrm{Var}\left(\hat{\theta}\right)+\left(B\left(\hat{\theta},\theta\right)\right)^2+2\left(\mathbb{E}\left[\hat{\theta}\right]-\theta\right)\underbrace{\mathbb{E}\left[\hat{\theta}-\mathbb{E}\left[\hat{\theta}\right]\right]}_{0} \\
&= \mathrm{Var}\left(\hat{\theta}\right)+B\left(\hat{\theta},\theta\right)^2
\end{aligned}
$$

□

1.5 Consistance

Propriété asymptotique. On ne considère que des estimateurs consistants.

Definition 1.10 (Consistance) – *Soit $(X_1,...,X_n)$ i.i.d. de loi P_θ. Soit $\hat{\theta}_n = h(X_1,...,X_n)$. $\hat{\theta}_n$ est un estimateur consistant (ou convergent) de θ ssi :*

$$\hat{\theta}_n \underset{n\to+\infty}{\overset{\mathbb{P}}{\longrightarrow}} \theta$$

Remarque 1.11 – *$\hat{\theta}_n$ est fortement consistant ssi $\hat{\theta}_n \underset{n\to+\infty}{\overset{\text{p.s.}}{\longrightarrow}} \theta$.* ◇

1.5.1 Exemple : Retour au modèle de Poisson

$\Theta = \mathbb{R}_+^*$, $\hat{\theta}_n = \overline{X}$.

- On peut invoquer la Loi des Grands Nombres (LGN) : $\overline{X} \overset{\mathbb{P}}{\longrightarrow} \mathbb{E}[X_i] = \theta$.
- Via le risque quadratique :

$$R\left(\hat{\theta}_n,\theta\right) = \mathrm{Var}\left(\overline{X}\right) = \frac{\theta}{n} \underset{n\to+\infty}{\longrightarrow} 0$$

D'après l'inégalité de Bienaymé-Tchebychev :

$$P\left(|\hat{\theta}_n-\theta|>\varepsilon\right) \leq \frac{\mathbb{E}\left[\left(\hat{\theta}_n-\theta\right)^2\right]}{\varepsilon^2} = \frac{R\left(\hat{\theta}_n,\theta\right)}{\varepsilon^2} \to 0$$

1.5.2 Méthode « Plug-in »

Soit $(X_1,...,X_n)$ i.i.d. Poisson(θ). On veut estimer $\beta = P(X_i=0) = e^{-\theta}$.

$$\hat{\beta} = e^{-\hat{\theta}} = e^{-\overline{X}}$$

$\hat{\beta}$ est consistant pour estimer β.

Lemme 1.12 (Lemme de l'application continue) – *Si $Z_n \overset{\mathbb{P}}{\longrightarrow} Z$, alors $h(Z_n) \overset{\mathbb{P}}{\longrightarrow} h(Z)$ pour toute fonction continue h.* ◇

Estimateurs

§2

2.1 Cadre paramétrique

2.1.1 Modèle statistique paramétrique

On dispose d'une observation $(X_1, ..., X_n)$, un échantillon de variable aléatoire i.i.d (indépendantes, identiquement distribuées) de loi commune P appartenant à une famille de lois de probabilités paramétrée $\{P_{\theta, \theta \in \Theta \subset \mathbb{R}^p}\}$.

Remarque 2.1 – *Si $\Theta \subset$ espace de dimension infinie $\to$ modèle non-paramétré.* ◇

Estimer P c'est estimer $\theta \in \mathbb{R}^p$.

Exemple 2.2 – Bernoulli *(θ)*, Exp *(θ)*, $\mathcal{N}(\mu, \sigma^2)$, *loi de densité* $f_\theta(x) = \theta x^{\theta-1} 1_{x \in [0,1]}$ ◇

Notation 2.3 – $E_{\theta_n}[h(X_1, ..., X_n)]$, $\Theta[h(X_1, ..., X_n)]$
Loi de $(X_1, ..., X_n) \to P_\theta^{\otimes n}$ ◇

Definition 2.4 (Estimateur) –

$$\hat{\theta} = \hat{\theta}_n = h(X_1, ..., X_n)$$

Definition 2.5 (Qualité) –

- *Risque*

$$R(\hat{\theta}, \theta) = E_\theta\left[\left(\hat{\theta} - \theta\right)^2\right]$$

- *Consistance*

$$\hat{\theta}_n \underset{n \to +\infty}{\overset{P}{\to}} \theta$$

Definition 2.6 (Modèle identifiable) –

$$\theta \to P_\theta \quad \text{injective}$$

2.2 Méthode des moments

Definition 2.7 – *On appelle* ***moment théorique*** *de la loi de X_i d'ordre k:*

$$\mu_k = E\left[X_i^k\right], \quad k \geq 1$$

Definition 2.8 – *On appelle* ***moment empirique*** *de la loi des X_i d'ordre k:*

$$\hat{\mu}_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$$

Par la loi des grands nombres $\hat{\mu}_k \underset{n\to+\infty}{\overset{P}{\longrightarrow}} \mu_k$.

La méthode des moments: si on peut écrire θ ou $g(\theta)$ paramètre d'intérêt comme une fonction des k premiers moments théoriques.

$$\theta = \mathcal{L}(\mu_1, ..., \mu_k)$$

alors l'estimateur

$$\hat{\theta} = \mathcal{L}(\hat{\mu}_1, ..., \mu_k)$$

est obtenu par la méthode.

Exemple 2.9 (Des calculs des estimateurs en utilisant la méthode des moments) –

- $X_i \sim \text{Bernoulli}(\theta)$ *à valeurs 0-1,*

$$\theta = P(X_i = 1) = E[X_i] \to \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

- $X_i \sim \text{Exp}(\theta)$,, $f_\theta(x) = \theta e^{-\theta x} 1_{x\geq 0}$, $E[X] = \frac{1}{\theta} \Longleftrightarrow \theta = \frac{1}{\mu_1}$, *par la méthode des moments,*

$$\hat{\theta} = \frac{1}{\hat{\mu}_1} = \frac{1}{\overline{X}}$$

$$\begin{aligned}\Theta(X_i) = \frac{1}{\theta^2} &\Longleftrightarrow \theta^2 = \frac{1}{E[X_i^2] - E[X_i]^2} \\ &\Longleftrightarrow \theta = \frac{1}{\sqrt{\mu_2 - \mu_1^2}} \\ &\Longrightarrow \hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \left(\overline{X}\right)^2}}\end{aligned}$$

- $X_1, ..., X_n$ *i.i.d. de la loi* P_θ *de densité*

$$f_\theta(x) = \theta x^{\theta-1} 1_{x\in[0,1]}$$

$$E_\theta[X_i] = \theta \int_0^1 x^\theta \, \mathrm{d}x = \frac{\theta}{\theta+1}$$

Méthode des moments:

$$(\theta+1)\mu_1 = \theta \Longleftrightarrow \theta(1-\mu_1) = \mu_1 \Longleftrightarrow \theta = \frac{E[X_i]}{1 - E[X_i]}$$

$$\Longrightarrow \hat{\theta}_{\mathbb{M}} = \frac{\overline{X}}{1-\overline{X}},, P_\theta\left(\overline{X} = 1\right) = P_\theta(X_1 = X_2 = ... = X_n = 1) = 0$$

◇

2.3 Rendu sur le L.A.C.

(L.A.C = lemme des applications continues) $(X_n)_{n\geq 1}$ suite de variables aléatoires. Si X_n converge vers X, que peut-on dire de $g(X_n)_{n\geq 1}$? Si g continue, LAC.

- si $X_n \xrightarrow[\mathcal{L}]{P} X$ alors $g(X_n) \xrightarrow[\mathcal{L}]{P} g(X)$
- si $X_n \xrightarrow{\mathcal{L}} X$ alors $g(X_n) \xrightarrow{\mathcal{L}} g(X)$

Remarque 2.10 (Condition suffisante) –

$$D_g = \{\text{points de discontinuité de } \ g\}$$

si $P\big(X \in D_g\big) = 0$, le LAC est vrai. ◇

Exemple 2.11 –

$$g(x) = \frac{x}{1-x}$$

- *LGN:* $\overline{X} \xrightarrow{P} E[X]$
- *LAC:* $g\big(\overline{X}\big) = \hat{\theta}_n \xrightarrow[n\to+\infty]{P} g(E[X]) = \theta$

◇

LAC pour des couples de suites de variables aléatoires:

- si $(X_n, Y_n) \xrightarrow[\mathcal{L}]{P} (X, Y)$, alors $g(X_n, Y_n) \xrightarrow[\mathcal{L}]{P} g(X, Y)$, si $g : \mathbb{R}^2 \to \mathbb{R}$ ou $\mathbb{R}^2$ continue
- si $(X_n, Y_n) \xrightarrow{\mathcal{L}} (X, Y)$, alors $g(X_n, Y_n) \xrightarrow{\mathcal{L}} g(X, Y)$

Exemple 2.12 –

$$\hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n}\sum_{i=1}^n X_i^2 - \big(\overline{X}\big)^2}} \quad \text{consistant?}$$

LGN:

- $\overline{X} \xrightarrow{P} \mu_1$
- $\frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2$

donc

$$\begin{pmatrix} \overline{X} \\ \frac{1}{n}\sum_{i=1}^n X_i^2 \end{pmatrix} \xrightarrow{P} \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

$g(x, y) = \frac{1}{\sqrt{y-x^2}} \Longrightarrow \hat{\theta}^{\mathbb{M}}$ *constant de θ, g continue sauf en $\big\{(x, y) \in \mathbb{R}^2, y = x^2\big\}$ de mesure nulle.*

Mais c'est faux pour une converge en loi. ◇

Proposition 2.13 (Convergence de couples) –

$$\begin{pmatrix} X_n \\ Y_n \end{pmatrix} \xrightarrow{P} \begin{pmatrix} X \\ Y \end{pmatrix} \quad \text{ssi} \quad \begin{cases} X_n \xrightarrow{P} X \\ Y_n \xrightarrow{P} Y \end{cases}$$

Preuve.

- $\Longrightarrow$ alors LAC $g(x,y) = x$ continue donc $X_n \to X$ et $Y_n \to Y$
- $\Longleftarrow$ convergence du couple?

$$\forall \varepsilon > 0, P(|X_n - X| + |Y_n - Y| > \varepsilon) \leq \underbrace{P\Big(|X_n - X| > \frac{\varepsilon}{2}\Big)}_{\to 0} + \underbrace{P\Big(|Y_n - Y| > \frac{\varepsilon}{2}\Big)}_{\to 0}$$

<u>Cette réciproque est fausse pour la converge en loi!</u>

□

2.3.1 Variance empirique

Si la X_i admettent une esperance μ et une variance σ^2, on appelle variance empirique

$$\begin{aligned}\hat{\sigma}_n^2 &= \frac{1}{n}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 + \frac{1}{n}\sum_{i=1}^n \overline{X}^2 - \frac{2}{n}\sum_{i=1}^n X_i\overline{X} \\ &= \frac{1}{n}\sum_{i=1}^n X_i^2 + \overline{X}^2 - 2\overline{X}\overline{X} = \tilde{\sigma}^2\end{aligned}$$

estimateur des moments:

$$\sigma^2 = E[X_i^2] - E[X_i]^2$$

On remplace les moments théoriques par les moments empiriques

$$\to \widetilde{\sigma^2}^{\mathbb{M}} = \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\overline{X}\right)^2$$

Consistance: $\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\overline{X}\right)^2$,

$$\begin{cases}\overline{X} \xrightarrow{P} E[X] \\ \frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{P} E[X^2]\end{cases} \xrightarrow{\text{cv en proba}} \begin{pmatrix}\overline{X} \\ \frac{1}{n}\sum_{i=1}^n X_i^2\end{pmatrix} \xrightarrow{\text{LAC}} \hat{\sigma}^2 \text{ consistant de } \mathrm{Var}(X) = E[X^2] - E[X]^2$$

Exemple 2.14 –

- *calculer le biais de* $\hat{\sigma}_n^2$
- *calculer le risque de* $\hat{\sigma}_n^2$

◇

2.4 Méthode de maximum de vraisemblance

2.4.1 Modèle donné

$(P_\theta)_{\theta\in\Theta}$ est donné s'il existe une mesure μ (positive σ définie $\to X_i$ à valeurs dans E, $E = \cup E_n$ avec $\mu(E_n)$ finie) telle que $\forall\theta, P_\theta$ admet une densité par rapport à μ.

2.4.2 En pratique

- soit E au plus dénombrable: $\mu =$ mesure de comptage. Si $\exists, \{a_1, a_2, ...\}$ tq $\sum_{k\geq 1} P_\theta(X_i = a_k) = 1$, alors $\mu = \sum_{k\geq 1}\delta_{a_k}$ avec $\delta_a(\{a\}) = 1$ mesure de dirac.

Exemple 2.15 – Bernoulli *(θ), $X_i = 1$, probas $\theta \to \mu = \delta_0 + \delta_1$ On écrira*

$$f_\theta(x) = \underbrace{P_\theta(\{x\})}_{=1-\theta} - P_\theta(X_i = x) \quad \text{avec} \quad x \in \{a_1, a_2, ...\}$$

◇

- soit $E = \mathbb{R}^p$, alors f_θ est la densité usuelle

f_θ densité de P_θ

Definition 2.16 – *On appelle vraisemblance de l'échantillon $(X_1, ..., X_n)$ la fonction*

$$\theta \to L_n(\theta) = \prod_{i=1}^{n} f_\theta(X_i) \quad \text{(variable aléatoire)}$$

Definition 2.17 – *Un estimateur du max de vraisemblance $\hat{\theta}_{MV}$ est définie par:*

$$\forall \theta \in \Theta, L_n(\theta) \leq L_n\left(\hat{\theta}\right)$$

On travaille souvent avec la **log-vraisemblance**

$$\log L_n(\theta) = \sum_{i=1}^{n} \ln f_\theta(X_i) \quad \text{somme de variables aléatoires}$$

$$\log L_n\left(\hat{\theta}\right) = \sup_{\theta \in \Theta} \log L_n(\theta)$$

Remarque 2.18 – *$\hat{\theta}$ est une variable aléatoire*

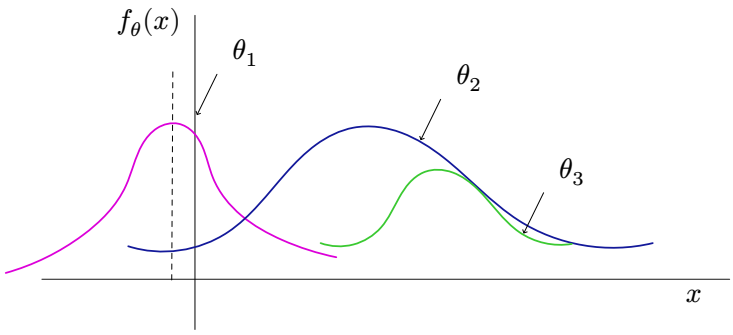

◇

fdsa

Exemple 2.19 –

- Bernoulli(θ), $f_\theta(x) = \theta^x(1-\theta)^{1-x}$, X_i *à valeurs 0-1*

$$L_n(\theta) = \prod_{i=1}^{n} \theta^{X_i}(1-\theta)^{1-X_i} = \theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}$$

$$\log L_n(\theta) = \left(\sum_{i=1}^{n} X_i\right)\ln\theta + \left(n - \sum_{i=1}^{n} X_i\right)\ln(1-\theta)$$

$$(\log L_n)'(\theta) = \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n-\sum_{i=1}^n X_i}{1-\theta} = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)}\left(\overline{X}-\theta\right)$$

Equation de vraisemblance:

$$(\log L_n)'(\theta) = 0 \Longleftrightarrow (1-\theta)\sum_{i=1}^{n} X_i = \left(n - \sum_{i=1}^{n} X_i\right)\theta$$

$$\Longleftrightarrow \sum_{i=1}^{n} X_i = n\theta \Longrightarrow \theta = \frac{\sum_{i=1}^n X_i}{n}$$

le point critique, est-il un maximum?

La dérivée change de signe en $\overline{X} \to$ *on a bien un max* $\to \hat{\theta}^{MV} = \overline{X}$

Condition du 2nd ordre, si $(\log L_n)''(\theta) < 0$ *pour tout* $\theta \Longrightarrow \log L_n$ *est concave* $\Longrightarrow$ *max global*

$$(\log L_n)''(\theta) = -\frac{\sum_{i=1}^n X_i}{\theta^2} - \frac{n-\sum_{i=1}^n X_i}{(1-\theta)^2} < 0,, \forall\theta$$

◇

Information de Fisher, efficacité

§3

Soit $(P_\theta)_{\theta\in\Theta}$, $\Theta \subset \mathbb{R}^p$ (identifiable, donnée). On note f_θ densité de P_θ

$$\operatorname{Supp} f_\theta = \left\{x \in E,, f_{\theta(x)} > 0\right\}$$

Étant donné $(X_1, ..., X_n)$, i.i.d. de loi P_θ et $\theta \mapsto L(\theta) = \prod_{i=1}^n f_{\theta(X_i)}$ la vraisemblance de l'échantillon. Sur $\operatorname{Supp} f_\theta$ on peut calculer

$$\log L_{n(\theta)} = \sum_{i=1}^n \log f_{\theta(X_i)}$$

$$\hat{\theta} = \operatorname{argmax}_{\theta\in\Theta} \log L_{n(\theta)}$$

Proposition 3.1 – *Si $\hat{\theta}$ EMV[1] de θ, $g\left(\hat{\theta}\right)$ est un EMV de $g(\theta)$*

Objectif: que peut-on avoir de « mieux » comme estimateur? $\longrightarrow$ modèle régulier

3.1 Modèle régulier

Definition 3.2 – *Le modèle $(P_\theta)_{\theta\in\Theta}$ est dit régulier si*

1. *Θ est un ouvert et $\theta \mapsto f_{\theta(x)}$ est C^1*
2. *$\operatorname{Supp} f_\theta$ ne dépend pas de θ: $S = \left\{x,\ f_{\theta(x)} > 0\right\}$*
3. *Pour tout θ, l'application*

$$x \mapsto \frac{\frac{\partial f_\theta}{\partial \theta}(x)}{f_{\theta(x)}} \mathbb{1}_{f_{\theta(x)}>0}$$

est intégrable (L, μ) et l'intégrale

$$I(\theta) = \int_S \frac{\frac{\partial f_\theta}{\partial \theta}(x)}{f_{\theta(x)}} \mathbb{1}_{f_{\theta(x)}>0} dx$$

est continue sur Θ.

Notation 3.3 – *On note la dérivée de $f_{\theta(x)}$ par rapport à θ: $\frac{\partial f_\theta}{\partial \theta}(x)$ La quantité $I(\theta)$ est appelée **Information de Fisher du modèle**.* ◇

Exemple 3.4 –

- *$f_{\theta(x)} = \theta e^{-x\theta}$ densité par rapport à $\mu(dx) = \mathbb{1}_{x\geq 0} dx$*

  $\theta \mapsto \theta e^{-x\theta}$ est C^∞ sur $\Theta =]0, +\infty[$, $\operatorname{Supp} f_\theta = \mathbb{R}_+$

$$\frac{\partial f_\theta}{\partial \theta}(x) = (1 - x\theta)e^{-x\theta}$$

[1] **EMV** = Estimateur de Maximum de Vraisemblance

$$\frac{(1-x\theta)^2\left(e^{-x\theta}\right)^2}{\theta e^{-x\theta}} = \frac{(1-x\theta)^2}{\theta}e^{-x\theta}$$

$$\begin{aligned} I(\theta) &= \int_\theta^\infty \frac{(1-x\theta)^2}{\theta^2}\theta e^{-x\theta}dx \\ &= \frac{1}{\theta^2}E_\theta(1-X\theta)^2 \\ &= \frac{1}{\theta^2}[1-2\theta E(X)+\theta^2 E(X^2)] = \frac{1}{\theta^2} \end{aligned}$$

continue sur $]0,+\infty[$

◇

Exemple 3.5 – Bernoulli(θ), $x = 0.1$, $f_{\theta(0)} = 1-\theta$, $f_{\theta(1)} = \theta$, *densité par rapport à* $\delta_0 + \delta_1$

Pour tout $x \in \{0,1\}$, $\theta \mapsto f_{\theta(x)}$ *est* C^1

$$\frac{\left(\frac{\partial f_{\theta(0)}}{\partial\theta}\right)^2}{f_{\theta(0)}} = \frac{1}{1-\theta}$$

$$\frac{\left(\frac{\partial f_{\theta(1)}}{\partial\theta}\right)^2}{f_{\theta(1)}} = \frac{1}{\theta} \Rightarrow I(\theta) = \frac{1}{1-\theta} + \frac{1}{\theta} = \frac{1}{\theta(1-\theta)}$$

continue sur $]0,1[$

◇

Exemple 3.6 – $f_{\theta(x)} = \frac{1}{\theta}\mathbb{1}_{[0,\theta]}(x) = \frac{1}{\theta}\mathbb{1}_{[x,+\infty[(\theta)}$ *modèle non régulier* ◇

3.2 Score et Information de Fisher

$(X_1, ..., X_n)$ i.i.d de loi de P_θ, f_θ

Definition 3.7 – *On appelle* ***score*** *ou* ***vecteur de score*** *la dérivée de la log vraisemblance* $\frac{\partial}{\partial\theta}\log L_{n(\theta)} = S_{n(\theta)} = \sum_{i=1}^n \frac{\partial}{\partial\theta}\log f_\theta(X_i)$

Exemple 3.8 – $X_i \sim \mathcal{E}(\theta)$, $L_{n(\theta)} = \theta^n e^{-\theta\sum_i X_i}$, $\log L_n(\theta) = n\log\theta - \theta\sum_i X_i$, *donc* $S - n(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X - i$ ◇

Remarque 3.9 –

$$E(S_n(\theta)) = E\left[n\left(\frac{1}{\theta} - \frac{\sum X_i}{n}\right)\right]$$

◇

Hyp supplémentaire de régularité: (H) pour tout estimateur $h(X)$ et tout θ, les intégrales suivantes existent et sont égales:

$$\frac{\partial}{\partial\theta}\int_S h(x)f_\theta(x)dx = \int_S h(x)\frac{\partial f_\theta}{\partial\theta}(x)dx$$

Remarque 3.10 – *condition d'application du thm de dérivation de Lebesgue.*

$$h\sup_{\tilde\theta\in V_\theta}|\frac{\partial f_\theta}{\partial\theta}(x)| \in L_1(\mu)$$

◇

Proposition 3.11 – *Sous (H), le score est centré (P_θ), $n=1$*

$$E_\theta\left[\frac{\partial}{\partial\theta}\log L_1(\theta)\right] = \int_S \frac{\partial}{\partial\theta}\log f_\theta(x)dx = \int_S \frac{\frac{\partial}{\partial\theta}f_{\theta(x)}}{\cancel{f_\theta(x)}}\cancel{f_\theta(x)}dx = \int_S \frac{\partial f_\theta}{\partial\theta}(x)dx \underbrace{=}_{(H)} \frac{\partial}{\partial\theta}\overbrace{\int f_\theta(x)dx}^{=1} = 0$$

Definition 3.12 – *L'information de Fisher associé à $(X_1,...,X_n)$*

$$I_n(\theta) \underbrace{=}_{\text{def}} E_\theta\left[\left(\frac{\partial}{\partial\theta}\log L_{n(\theta)}\right)^2\right] \overbrace{=}^{\text{cor. de la prop 1}} = \mathrm{Var}_\theta\left[\frac{\partial\log L_n(\theta)}{\partial\theta}\right]$$

$$(*)E_\theta\left[\frac{\partial}{\partial\theta}\log f_\theta(X_1)\right]^2 = \int_S\left(\frac{\frac{\partial}{\partial\theta}f_\theta(x)}{f_\theta(x)}\right)^2 f_\theta(x)dx = \int_S\frac{\left(\frac{\partial}{\partial\theta}f_\theta(x)\right)^2}{f_\theta(x)} = \text{"expression de la definition 1"}$$

Exemple 3.13 – $(X_1,...,X_n)\sim\mathcal{E}(\theta)$, $\frac{\partial}{\partial\theta}\log L_n(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X_i$

$$I_n(\theta) = E\left(\left(\frac{n}{\theta} - \sum X_i\right)^2\right) = n^2E\left[\left(\frac{1}{\theta} - \frac{\sum X_i}{n}\right)^2\right] = n^2\,\mathrm{Var}\left(\overline{X}\right) = n^2\frac{1}{n}\frac{1}{\theta^2} = \frac{n}{\theta^2}$$

◇

Proposition 3.14 –

$$I_n(\theta) = nI(\theta)$$

en effet,

$$I_n(\theta) = \mathrm{Var}\left(\frac{\partial}{\partial\theta}\log L_n(\theta)\right) = \mathrm{Var}\left(\sum_{i=1}^n\frac{\partial}{\partial\theta}\log f_\theta(X_i)\right) \underbrace{=}_{\text{independance}} = \sum_{i=1}^n\mathrm{Var}\left(\frac{\partial}{\partial\theta}\log f_\theta(X_i)\right) =$$

$$= n\underbrace{\mathrm{Var}\left(\frac{\partial}{\partial\theta}\log f_\theta(X_1)\right)} = nI(\theta)$$

Exemple 3.15 – $(X_1,...,X_n)$ *i.i.d* $\mathcal{P}(\theta)$, $f_\theta(x) = e^{-\theta}\frac{\theta^x}{x!}$

$$\log L_n(\theta) = -n\theta + \left(\sum X_i\right)\log\theta - \log\prod_{i=1}^n X_i!$$

$$\frac{\partial}{\partial\theta}\log L_n(\theta) = -n + \frac{\sum X_i}{\theta} \Rightarrow I_n(\theta) = \mathrm{Var}\left(\frac{\sum X_i}{\theta}\right) = \frac{1}{\theta^2}n\theta = \frac{n}{\theta}$$

◇

3.3 Information de Fisher et derivée seconde

Proposition 3.16 – *En ajoutant que $\theta \mapsto f_\theta(x)$ est C^2 et que (H) vrai pour $\frac{\theta^2}{\partial\theta^2}$ alors l'info de Fisher s'écrit encore*

$$I_n(\theta) = -E_\theta\left[\frac{\partial^2 \log L_n(\theta)}{\partial\theta^2}\right]$$

si $\hat{\theta}$ EMV, $I_{n(\hat{\theta})} > 0$

$n = 1$

$\frac{\partial^2}{\partial\theta^2}\log f_\theta(x) = \frac{\left(\frac{\partial^2 f_\theta(x)}{\partial\theta^2}\right)^2}{f_\theta(x)} - \frac{\left(\frac{\partial f_\theta}{\partial\theta}(x)\right)^2}{f_\theta^2(x)}$

$$E\left[\frac{\partial^2}{\partial\theta^2}\log f_\theta(X_1)\right] = \int_S \frac{\frac{\partial^2 f_{\theta(x)}}{\partial\theta^2}}{\cancel{f_\theta(x)}}\cancel{f_\theta(x)}dx - \underbrace{\int_S \frac{\left(\frac{\partial f_\theta(x)}{\partial}\theta\right)^2}{f_\theta^2(x)}dx}_{I(\theta)}$$

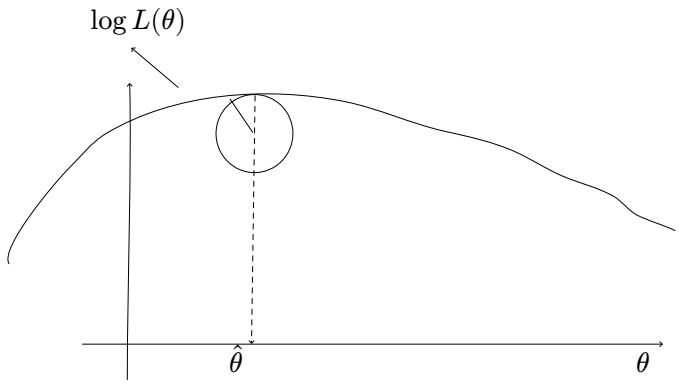

Si courbe très « piqué » en l'EMV (i.e. info. Fisher est grande) alors l'EMV est localisé de façon précise

3.4 Inégalité de Cramer - Rao

Soit $g(\theta)$ le paramètre d'intérêt où $g : \Theta \to \mathbb{R}$

Proposition 3.17 – *Sous les hypothèses d'un modèle régulier, si pour tout θ, $I(\theta) > 0$, alors pour tout estimateur $T = T(X_1, ..., X_n)$ <u>sans biais</u>, $E_\theta T^2 < +\infty$, on a*

$$\forall \theta \in \Theta, \underbrace{\mathrm{Var}_\theta(T) \geq \frac{(g'(\theta)^2)}{I_n(\theta)}} = \frac{(g'(\theta))^2}{nI(\theta)}$$

Preuve.

$$\begin{aligned}
&\forall \theta \;\; E_{\theta(T)} = g(\theta) \\
&\Rightarrow \frac{\partial}{\partial \theta} E_\theta(T) = g'(\theta) \\
T=T(X_1) \Leftrightarrow &\frac{\partial}{\partial \theta} \int_S T(x) f_\theta(x) dx = g'(\theta) \\
(H) \Leftrightarrow &\int_S T(x) \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} f_\theta(x) dx = g'(\theta) \\
\Leftrightarrow &\int_S (T(x) - g(\theta)) \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} f_\theta(x) dx = g'(\theta)
\end{aligned}$$

□

Inégalité de Cauchy-Schwarz pour $\langle h_1, h_2 \rangle = \int h_1(x) h_2(x) f_\theta(x) dx$ avec $h_1(X)$ et $h_2(X)$ centrées

$$\left(\langle T(X) - g(\theta), \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} \rangle_\theta \right)^2 = (g'(\theta))^2 \underbrace{=}_{\text{c.s}} \underbrace{\int (T(x) - g(\theta))^2 f_\theta(x) dx}_{= \mathrm{Var}_\theta(T)} \times \underbrace{\int \left(\frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} \right)^2 f_\theta(x) dx}_{= I(\theta)}$$

Definition 3.18 – *Si T réalise l'égalité, alors T est dit* ***efficace****.*

Étude asymptotique des estimateurs

§4

Dans un moddèle paramétrique <u>régulier</u>, si $\hat{\theta}_n$ estimateur de θ, alors

$$\operatorname{Var}\left(\hat{\theta}_n\right) \geq \frac{1}{I_{n(\theta)}} = \frac{1}{nI(\theta)}$$

si $\operatorname{Var}\left(\hat{\theta}_n\right) = \frac{1}{nI(\theta)}$ sans biais, $\hat{\theta}_n$ est efficace <u>efficace</u>

Asymptotique: $n \to +\infty$,

$$n \operatorname{Var}\left(\hat{\theta}_n\right) \underset{n\to+\infty}{\longrightarrow} \frac{1}{I(\theta)}$$

4.1 Convergences

$(X_n)_{n\geq 0}$ suite de variables aléatoires réelles $\left(\mathbb{R}^d\right)$

- convergence en loi: $X_n \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} X$ ssi $P(X_n \leq x) \longrightarrow P(X \leq x)$ en tout point de continuité de x.

Lemme 4.1 (lemme de Portmanteau) – *Caractérisations équivalentes:*

- *Pour toute fonction continue bornée h,*

$$E[h(X_n)] \longrightarrow E[h(X)]$$

$\Rightarrow$ la convergence en loi est stable par passage aux fonctions continues (LAC) <u>MAIS</u> il est en général <u>faux</u> que si $X_n \overset{\mathcal{L}}{\longrightarrow} X$ et $Y_n \overset{\mathcal{L}}{\longrightarrow} Y$ alors $\binom{X_n}{Y_n} \overset{\mathcal{L}}{\longrightarrow} \binom{X}{Y}$

Cela est vrai dans 3 cas:

1. si $\begin{cases} \forall n, X_n \text{ et } Y_n \text{ sont indépendantes} \\ X \text{ et } Y \text{ sont indépendantes} \end{cases}$ alors $\begin{cases} \text{convergence en loi de } X_n \text{ et } Y_n \\ \text{convergence en loi du couple } \binom{X_n}{Y_n} \end{cases}$

2.

$$\text{si } \begin{cases} X_n \overset{P}{\longrightarrow} X \\ Y_n \overset{p}{\longrightarrow} Y \end{cases} \Longrightarrow \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{P}{\longrightarrow} \begin{pmatrix} X \\ Y \end{pmatrix} \Longrightarrow \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{\mathcal{L}}{\longrightarrow} \begin{pmatrix} X \\ Y \end{pmatrix}$$

3. (Lemme de Slutsky) (le plus important)

$$\text{si } \begin{cases} X_n \overset{\mathcal{L}}{\longrightarrow} X \\ Y_n \overset{\mathcal{L}}{\longrightarrow} c \end{cases} \text{ alors } \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{\mathcal{L}}{\longrightarrow} \begin{pmatrix} X \\ c \end{pmatrix}$$

en appliquant le LAX,

$$\begin{aligned} h(x,y) &= x+y & X_n + Y_n &\xrightarrow{\mathcal{L}} X + c \\ &= xy & X_n Y_n &\xrightarrow{\mathcal{L}}\xrightarrow{\mathcal{L}} cX \\ &= \frac{x}{y} & \frac{X_n}{Y_n} &\xrightarrow{\mathcal{L}} \frac{X}{c} \end{aligned}$$

◇

4.2 Consistance des estimateurs

Definition 4.2 – *$\hat{\theta}_n$ asymptotiquement sans biais si et seulement si*

$$\text{Biais}\left(\hat{\theta}_n, \theta\right) = E\left[\hat{\theta}_n\right] - \theta \underset{n\to+\infty}{\longrightarrow} 0$$

Remarque 4.3 – *La convergence en proba n'implique pas la convergence des espérances.*

Si $X_n \xrightarrow{P} X$, $|X_n| \leq Y \in L'$, alors par convergence dominée $X_n \longrightarrow X$ dans L_1 ◇

Exemple 4.4 – $\hat{\tau}_n = \frac{1}{n}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2 = \frac{1}{n}\sum X_i^2 - \left(\overline{X}\right)^2$ *estimateur des moments de* $\tau^2 = E[X^2)] - (E[X])^2$

$$\text{Biais}(\hat{\tau}_n^2, \tau^2) = -\frac{1}{n}\tau^2 \quad \text{asymptotiqument sans biais}$$

Consistance de $\hat{\tau}_n^2$?

Outils pour montrer la consistance:

- *LGN*
- *si $R\left(\hat{\theta}_n, \theta\right) \longrightarrow 0$ alors $\hat{\theta}_n$ consistant car convergence $L^2 \Rightarrow$ convergence en probas*
- *revenir à la définition de convergence en probas*

- *si (X_i) sont i.i.d., alors (X_i^2) est i.i.d.*

$$E[X_i^2] < +\infty$$

  LGN: $\frac{1}{n}\sum_i X_i^2 \xrightarrow{P} E[X^2] = \tau^2 - \mu^2$
- $\overline{X} \xrightarrow{P} \mu$ *(LGN), LAC avec $h(x) = x^2$:* $\left(\overline{X}\right)^2 \xrightarrow{P} \mu^2$
- *Donc* $\begin{pmatrix} \frac{1}{n}\sum_{i=1}^n X_i^2 \\ \frac{1}{n}\sum X_i \end{pmatrix} \xrightarrow{P} \begin{pmatrix} \tau^2 - \mu^2 \\ \mu \end{pmatrix}$
- *LAC $h(x,y) = x - y^2$*

Donc $\frac{1}{n}\sum X_i^2 - \left(\overline{X}\right)^2 \xrightarrow{P} \tau^2 + \mu^2 - \mu^2 = \tau^2$ ◇

4.3 Normalité asymptotique

$\hat{\theta}_n$ pour θ.

$\rightarrow$ Question: quelle est la vitesse de convergence de $\hat{\theta}_n$ vers θ ?

$(X_1, ..., X_n)$ i.i.d., d'espérance θ, $\hat{\theta} = \overline{X}$ de variance $\tau^2(\theta)$

TLC $\sqrt{n}\big(\overline{X}-\theta\big) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,\tau^2(\theta))$ quelle que soit la loi des X_i

Definition 4.5 – *$\hat{\theta}_n$ est un estimateur asymptotiquement normal si et seulement si*

- *vitesse de convergence en $\sqrt{n}$*
- *convergence en loi*
- *loi limite est normale*

$$\sqrt{n}\big(\hat{\theta}_n-\theta\big) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,\tau^2(\theta))$$

Exemple 4.6 – *$\hat{\tau}_n^2$ est-elle asymptotiqument normale ?*

$(X_1,...,X_n)$ i.i.d. d'espérance μ, de variance τ^2

$$\hat{\tau}_n^2 = \frac{1}{n}\sum_{i=1}^n \big(X_i-\overline{X}\big)^2 = \frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2 + \big(\overline{X}-\mu\big)^2 + \underbrace{\frac{2}{n}\sum_{i=1}^n (X_i-\mu)\big(\mu-\overline{X}\big)}_{=2\left(\mu-\overline{X}\right)\left(\overline{X}-\mu\right)}$$

- *TLC: si (X_i) i.i.d., alors les $(X_i-\mu)^2$ sont i.i.d. d'esperance τ^2,*

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2-\tau^2\right) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,u_4-\tau^4)$$

$$\mathrm{Var}(X_i-\mu)^2 = E\Big[(X_i-\mu)^4\Big]-\mu^4 = \mu_4-\tau^4$$

- *TLC:* $\sqrt{n}\big(\overline{X}-\mu\big) \xrightarrow{\mathcal{L}} \mathcal{N}(0,\tau^2)$
- $\sqrt{n}(\hat{\tau}_n^2-\tau^2) = \sqrt{n}\big(\frac{1}{n}\sum_i (X_i-\mu)^2-\tau^2\big) - \underbrace{\sqrt{n}\big(\overline{X}-\mu\big)^2}_{\sqrt{n}\underbrace{\left(\overline{X}-\mu\right)}_{\xrightarrow{\mathcal{L}}\mathcal{N}(0,\tau^2)} \times \underbrace{\left(\overline{X}-\mu\right)}_{\xrightarrow{\mathcal{L},P} 0}}$

$$\left.\begin{array}{l} \overline{X}-\mu \xrightarrow{\mathcal{L}} 0 \\ \sqrt{n}\big(\overline{X}-\mu\big) \xrightarrow{\mathcal{L}} U \sim \mathcal{N}(0,1) \end{array}\right\} \overset{\text{lemme de Slutsky}}{\Longrightarrow} \sqrt{n}\big(\overline{X}-\mu\big)^2 \xrightarrow[P]{\mathcal{L}} 0$$

$$\sqrt{n}(\hat{\tau}_n^2-\tau^2) \xrightarrow[n\to+\infty]{\mathcal{L}} Z+0$$

Donc $\hat{\tau}_n^2$ est un estimateur asymptotiqument normal ◇

Remarque 4.7 – $\sqrt{n}\big(\hat{\theta}_n-\theta\big) \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,\tau^2) \Longleftrightarrow \frac{\sqrt{n}\left(\hat{\theta}_n-\theta\right)}{\tau} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$ *Application du lemme de Slutsky: si $\hat{\tau}^2$ est un estimateur consistant de τ^2, alors on a encore*

$$\frac{\sqrt{n}\big(\hat{\theta}_n-\theta\big)}{\hat{\tau}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

◇

Preuve.

$$\frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\hat{\tau}} = \underbrace{\left(\sqrt{n}\frac{\left(\hat{\theta}-\theta\right)}{\tau}\right)}_{\xrightarrow{\mathcal{L}} Z\sim\mathcal{N}(0,1)} \times \underbrace{\left(\frac{\tau}{\hat{\tau}}\right)}_{\xrightarrow{P} 1}$$

$$\xrightarrow{\mathcal{L}} 1 \times Z \text{ par Slutsky et consistance de } \hat{\tau}$$

□

4.4 δ-méthode

$\hat{\theta}$ estimateur asymptotiquement normal: quelle est la loi asymptotique de $g(\theta)$?

Lemme 4.8 (méthode délta) – *Soit Z_n suite de variables aléatoires réelles t.q.*

$$\sqrt{n}(Z_n-\mu) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,\tau^2)$$

Soit g une fonction dérivable, $g'(\mu) \neq 0$. Sous ces hypothèses, on a

$$\sqrt{n}[g(Z_n)-g(\mu)] \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \tilde{Z} \sim \mathcal{N}\left(0,(g'(\mu))^2\tau^2\right)$$

$$g(x) = g(\mu) + g'(\mu)(x-\mu) + (x-\mu)R(x-\mu) \quad \text{où} \quad R(y) \underset{y\to 0}{\to} 0$$

$$\sqrt{n}(g(Z_n)-g(\mu)) = \underbrace{g'(\mu)\underbrace{\sqrt{n}(Z_n-\mu)}_{\xrightarrow{\mathcal{L}} Z\sim\mathcal{N}(0,\tau^2)}}_{\to\mathcal{N}\left(0,(g'(\mu))^2\tau^2\right)} + \underbrace{\underbrace{\left(\sqrt{n}\right)(Z_n-\mu)}_{\xrightarrow{\mathcal{L}}\mathcal{N}(0,\tau^2)}\underbrace{R(Z_n-\mu)}_{\xrightarrow{P} 0?}}$$

A-t-on $Z_n \xrightarrow{P} \mu$?

$$\begin{aligned}
P(|X_n-\mu|>\varepsilon) &= P\left(\frac{\sqrt{n}|Z_n-\mu|}{\tau} > \frac{\sqrt{n}\varepsilon}{\tau}\right) \\
&= P\left(\frac{\sqrt{n}(Z_n-\mu)}{\tau} > \frac{\sqrt{n}\varepsilon}{\tau}\right) + P\left(\frac{\sqrt{n}(Z_n-\mu)}{\tau} < -\frac{\sqrt{n}\varepsilon}{\tau}\right) \\
&\sim= 1-\Phi_n\left(\frac{\sqrt{n}\varepsilon}{\tau}\right) + \Phi_n\left(-\frac{\sqrt{n}\varepsilon}{\tau}\right) = 2\left(1-\Phi\left(\frac{\sqrt{n}\varepsilon}{\tau}\right)\right)
\end{aligned}$$

◇

Fonction de répartition empirique

§5

$(X_1, ..., X_n)$ échantillon i.i.d. à valeurs réelles de loi F inconnue.

$$\forall x \in \mathbb{R}, F(x) = P(X_1 \leq x) = E\left[\mathbb{1}_{X_1 \leq x}\right]$$

Definition 5.1 – *La fonction de répartition <u>empirique</u> associée à $(X_1, ..., X_n)$ est définie par:*

$$\begin{aligned} \hat{F}_n : \mathbb{R} &\longrightarrow [0,1] \\ x &\mapsto \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{X_i \leq x} \end{aligned}$$

$\forall x \in \mathbb{R}, \hat{F}_n(x)$ est une variable aléatoire, estimateur de $F(x)$.

Definition 5.2 – *Loi empirique $P_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i}$ est une loi discrète uniforme sur $\{X_1, ..., X_n\}$.*

Représentation graphique

Conditionnelement $X_1 = x_1, X_2 = x_2, ..., X_n = x_n$

$$x_{(1)} \leq x_{(2)} \leq ... \leq x_{(n)} \quad \text{valeurs ordonnées}$$

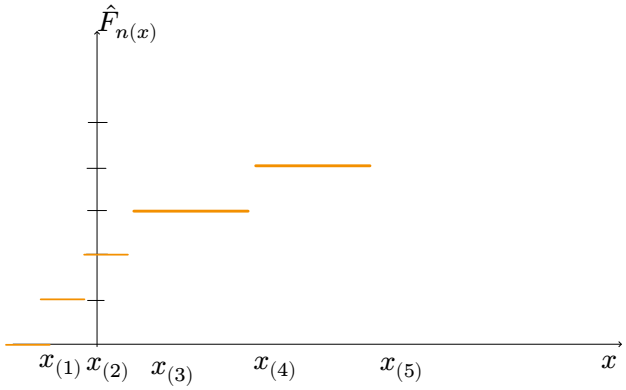

fdsa

Proposition 5.3 (Propriétés immédiats) –

- *$n\hat{F}_n(x) = \sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}$ suit la loi binomiale$(n, F(x))$*
- *$R\left(\hat{F}_n(x), F(x)\right) = 0 + \frac{1}{n^2}\operatorname{Var}\left(\sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}\right) \underbrace{=}_{\text{indep}} \frac{1}{n}F(x)(1 - F(x)) \underset{n \to +\infty}{\longrightarrow} 0$ donc $\forall x \in \mathbb{R}, \hat{F}_n(x) \xrightarrow{P} F(x)$*
- *ou bien <u>LGN</u>: $\hat{F}_n(x)$ estimateur <u>consistant</u> de $F(x)$.*

- *On a un résultat de convergence uniforme :*

$$\sup_{x\in\mathbb{R}}|\hat{F}_n(x) - F(x)| \xrightarrow[n\to+\infty]{P} 0 \quad \text{(Théorème de Glivenko-Cantelli)}$$

.[2]

- $\hat{F}_n(x)$ *est-il asymptotiqument normal?*

$$\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{X_i\leq x}$$

TLC: les X_i *sont i.i.d., donc les* $\left\{\mathbb{1}_{X_i\leq x} = Y_i\right\}$ *sont i.i.d.*

$$\forall x, F(x) \in]0,1[, \quad \sqrt{n}\left(\hat{F}_n(x) - F(x)\right) \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0, F(x)(1-F(x)))$$

$$\iff \frac{\hat{F}_n(x) - F(x)}{\sqrt{\frac{F(x)(1-F(x))}{n}}} \xrightarrow[n\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$$

5.1 Estimation empirique

« plug-in » ou méthode de substitution, paramètre d'intérêt $\theta = c(F)$, la méthode empirique définit $\hat{\theta}$, estimateur impirique en remplaçant F par $\hat{F}_n \to \hat{\theta}_n = c\left(\hat{F}_n\right)$.

Exemple 5.4 – $\theta = E_F(X) \to \hat{\theta}_n = E_{\hat{F}_n}(X) = \sum_{i=1}^{n} X_i \times \frac{1}{n} = \overline{X}$ *si* X_i *distinctes*

$$\theta = \mathrm{Var}_F(X) \to \hat{\theta}_n = \mathrm{Var}_{\hat{F}_n}(X) = \frac{1}{n}\sum\left(X_i - \overline{X}\right)^2$$

◇

5.2 Inverse généralisé

Definition 5.5 – *On définit l'inverse généralisé de* F *par:*

$$F^{-1} : [0,1] \longrightarrow \mathbb{R}$$

$$\forall \alpha \in [0,1], F^{-1}(\alpha) = \inf\{x \in \mathbb{R}, F(x) \geq \alpha\}$$

Si F *est strictement croissante,* $\inf x$ *tel que* $F(x) \geq a \Leftrightarrow x \geq F^{-1}(\alpha)$*, si* F *est la fonction d'une loi discrète.*

[2] Thm de Glivenko-Cantelli: https://fr.wikipedia.org/wiki/Th%C3%A9or%C3%A8me_de_Glivenko-Cantelli

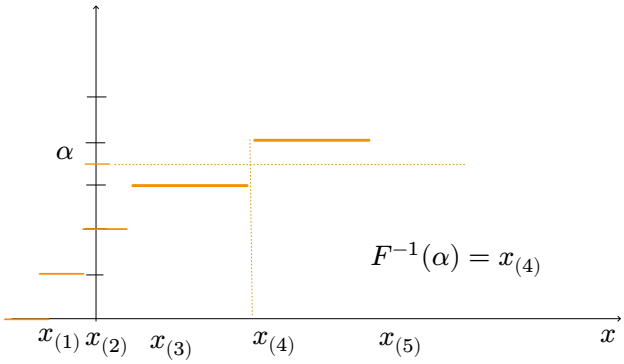

Exemple 5.6 –

$$F^{-1}(\alpha) = x \Leftrightarrow F(x) = \alpha \Leftrightarrow P(X \leq x) = \alpha \Leftrightarrow P(X > x) = 1 - \alpha$$

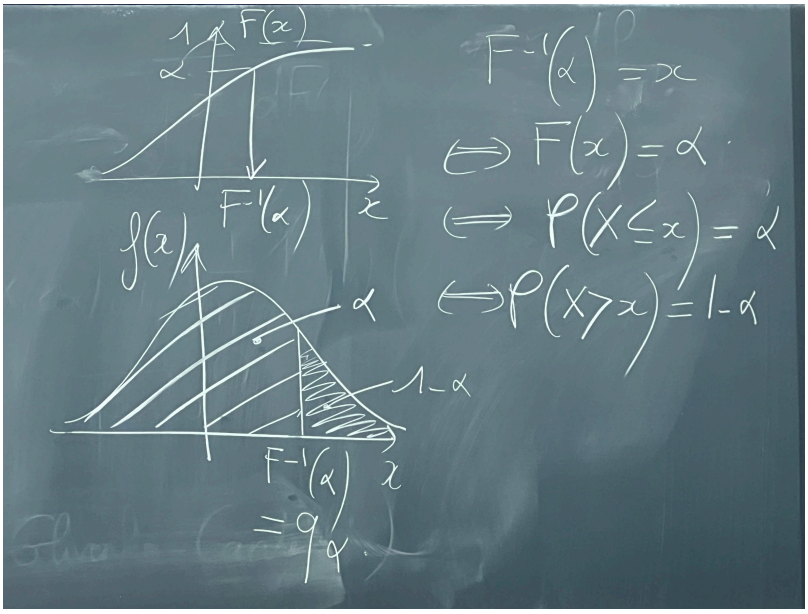

◇

Vocab:

- F^{-1} s'appelle aussi la <u>fonction quantile</u>
- $F^{-1}(\alpha)$ = quantile d'ordre α, de la loi F
- $F^{-1}\left(\frac{1}{4}\right)$ = 1er quantile
- $F^{-1}\left(\frac{1}{2}\right)$ = médiane
- $F^{-1}\left(\frac{3}{4}\right)$ = 3eme quantile

Lemme 5.7 – *U variable aléatoire sur $[0,1]$, F f.r., alors $F^{-1}(U)$ est une variable aléatoire de loi F* ◇

- Si F bijective:

$$P(F^{-1}(U) \leq x) \underbrace{=}_{F \text{ bijective}} P(U \leq F(x)) \underbrace{=}_{\text{car } P(U \leq x) = x \text{ sur } [0,1]} F(x)$$

- Si F discrète: F^{-1} inverse généralisé: $F^{-1}(y) \leq x \Leftrightarrow y \leq F(x)$

5.3 Quantile empirique

Definition 5.8 – *On définit le <u>quantile empirique</u> (sampe quantile) d'ordre α, comme étant le quantile de $\hat{F}_n$:*

$$\hat{q}_{n,\alpha} = \hat{F}_n^{-1}(\alpha) = \inf\Big\{x, \hat{F}_n(x) \geq \alpha\Big\}$$

Proposition 5.9 –

- *On peut montrer que $\hat{q}_{n,\alpha} = X_{([n\alpha])}$ où $X_{(1)} \leq X_{(2)} \leq ... \leq X_{(n)}$ est l'echantillon ordoné des $(X_i)_{1 \leq i < n}$*

$$[u] = \text{le plus petit entier} \geq u$$

Exemple 5.10 – $\alpha = \frac{1}{2}$, $\left[\frac{n}{2}\right]$,

$$\begin{cases} \text{si } n = 2k \quad \text{medianne} = \hat{q}_{n,\frac{1}{2}} = X_{(k)} \\ \text{si } n = 2k+1 \quad \text{medianne} = \hat{q}_{n,\frac{1}{2}} = X_{(k+1)} \end{cases}$$

- *Consistance*

  si $\alpha \in]0,1[$, si F est strictement croissante au voisinage de α

◇

Intervalles de confiance

§6

6.1 Définitions

$(X_1, ..., X_n)$ i.i.d. de loi $P \in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$, on s'interesse à $\theta \in \mathbb{R}$ ou $g(\theta) : \mathbb{R}^p \longrightarrow \mathbb{R}$.

Un intervalle de confiance pour θ, de niveau de confiance $1-\alpha, \alpha \in]0,1[$ est un intervalle dont les bornes sont <u>aléatoires</u>, fonctions de l'échantillon et ne dépend PAS des paramètres inconnus du modèle et tel que

$$P([B\inf(X_1, ..., X_n); B\sup(X_1, ..., X_n)] \ni \theta) \geq 1-\alpha$$

[3]

- Un IC est calculable à partir des données
- si l'inégalité est une égalité = niveau de confiance est <u>exact</u>.
- si on a $P(\theta \in [B\inf, B\sup]) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$, niveau est <u>asymptotique</u>.
- en général $\alpha = 1\%, 5\%$

6.2 Interprétation

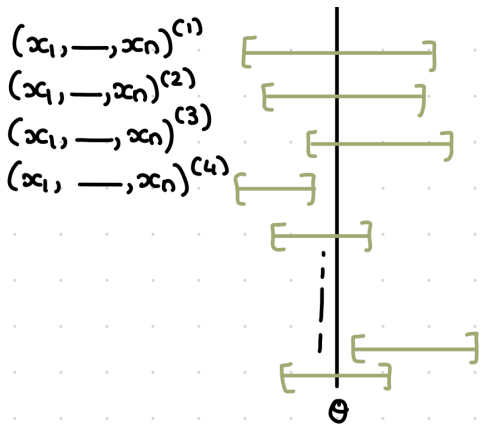

$IC = [B\inf(X_1, ..., X_n), B\sup(X_1, ..., X_n)]$ formule mathématique qui g´arantit le niveau $1-\alpha$. On observe $X_1 = x_1, X_2 = x_2, ..., X_n = x_n$, une réalisation de l'échantillon aléatoire. On calcule $IC = [2.3; 5.1]$ de niveau de confiance 95% ($\alpha = 5\%$).

En moyenne, sur 100 intervalles calculés (avec la même formule), il y a 5 intervalles qui ne contiennent pas θ.

$$P(\theta \in [B\inf, B\sup]) = 1-\alpha$$

$\cancel{P(\theta \in [2.3, 5.1]) = 95\%}$ car θ un nombre

6.3 Méthode pivotale

$(X_1, ..., X_n)$ i.i.d. d'espérance $\theta \in \mathbb{R}$, de variance $\sigma^2(\theta)$. Soit $\hat{\theta}$, asymptotiquement normal:

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0, \sigma^2(\theta))$$

$$\Leftrightarrow \frac{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}{\sigma(\theta)} \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0,1)$$

Par définition des quantiles gaussiens, $q_\alpha = \Phi^{-1}(\alpha)$ où Φ f.r. de $\mathcal{N}(0,1)$

[3] $B\inf$ pour borne inférieure et $B\sup$ pour borne supérieure

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\sigma(\theta)} \leq q_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

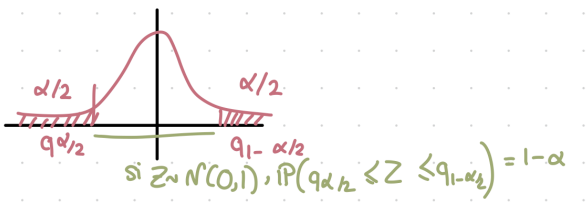

- **pivot ou statistique pivotale** $= \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\hat{\sigma}}$ statistique centrée réduite issue de $\hat{\theta}$, où $\sigma^2(\theta)$ estimé par $\hat{\sigma}^2$, <u>consistant</u> pour estimer $\sigma^2(\theta)$.

  Si c'est le cas,

$$\underbrace{\frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\sigma(\theta)}}_{\underset{\hat{\theta}\text{ as. normal}}{\overset{\mathcal{L}}{\longrightarrow}}\ \mathcal{N}(0,1)} \times \underbrace{\frac{\sigma^2(\theta)}{\hat{\sigma}^2}}_{\underset{\text{estimateur consistant}}{\overset{P}{\longrightarrow}}\ 1} \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0,1) \quad \text{par lemme de Slutsky}$$

- on en déduit

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\hat{\sigma}}(\theta) \leq q_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

$$P\left(\hat{\theta} - \frac{1}{\sqrt{n}}\hat{\sigma}q_{1-\frac{\alpha}{2}} \leq \theta \leq \hat{\theta} - \frac{1}{\sqrt{n}}\hat{\sigma}q_{\frac{\alpha}{2}}\right) \longrightarrow 1-\alpha$$

Compléments (avant partiel)

§7

1. Retour sur normalité asymptotique
2. Exemple
3. Pivot asymptotique
4. Exemple 2

7.1 Propriétés asymptotiques d'une suite d'estimateurs $\left(\hat{\theta}_n\right)_{n\geq 1}$

- Consistance $\hat{\theta}_n \xrightarrow{P} \theta$
- Normalité asymptotique, s'il existe $\sigma^2 > 0$

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \mathcal{N}(0,\sigma^2)$$

De façon générale, s'il existe $v_n \underset{n\to+\infty}{\longrightarrow} +\infty$

$$v_{n\left(\hat{\theta}_n-\theta\right)} \xrightarrow{\mathcal{L}} Y$$

On dit que $\hat{\theta}_n$ converge à la vitesse $\frac{1}{v_n}$

Remarque 7.1 – *Si $\hat{\theta}_n$ asymptotiquement normal $\Rightarrow$ $\hat{\theta}_n$ consistant*

$$\hat{\theta}_n - \theta = \underbrace{\frac{1}{\sqrt{n}}}_{\to 0} \underbrace{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}_{\xrightarrow{\mathcal{L}}\mathcal{N}(0,\sigma^2)} \underset{\text{Slutsky}}{\xrightarrow{\mathcal{L}\text{ ou }P}} 0$$

$$U_n = \frac{1}{\sqrt{n}} \to 0$$

◇

<u>δ-méthode</u>

$$\sqrt{n}(X_n - 1) \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$
$$\sqrt{n}(X_n - 1) \overset{\mathcal{L}}{\approx} Z \sim \mathcal{N}(0,1)$$
$$X_n \overset{\mathcal{L}}{\approx} 1 + \frac{1}{\sqrt{n}} Z$$

Si g dérivable en 1,

$$g(1+h) = g(1) + hg(1)$$

$$g(X_n) \approx g(1) + \frac{1}{\sqrt{n}} g'(1) Z$$

$$\sqrt{n}(g(X_n) - g(1)) \approx g'(1) Z$$

<u>δ-méthode</u>

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,1)$$

g dérivable en θ

$$g(x) = g(\theta) + g'(\theta)[(x-\theta) + r(x)] \text{ où } r(x) \underset{x\to 0}{\to} 0$$

$\hat{\theta}_n \xrightarrow{P} \theta$ donc (LAC) $r\left(\hat{\theta}_n\right) \longrightarrow r(\theta) = 0$

$$g\left(\hat{\theta}_n\right) = g(\theta) + \left(\hat{\theta}_n - \theta\right)\left[g'(\theta) + r\left(\hat{\theta}_n\right)\right]$$

$$\sqrt{n}\left(g\left(\hat{\theta}_n\right) - g(\theta)\right) = \underbrace{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}_{\xrightarrow{\mathcal{L}} Z}\left[\underbrace{g'(\theta) + r\left(\hat{\theta}_n\right)}_{\xrightarrow{P} g'(\theta)}\right] \underset{\text{Slutsky}}{\Rightarrow} \sqrt{n}\left(g\left(\hat{\theta}_n\right) - g(\theta)\right) \xrightarrow{\mathcal{L}} g'(\theta)Z \sim \mathcal{N}\left(0, (g'(\theta))^2\right)$$

Exemple 7.2 – *$X_1, .., X_n$ de loi de densité $f(x) = \frac{1}{\mu}e^{-\frac{x}{\mu}}, x \geq 0, \mu = E[X_i] > 0$*

μ estimé par $\hat{\mu} = \overline{X}$ efficace? $\log L_n(\mu) = -n\log\mu - \frac{1}{\mu}\sum_{i=1}^n X_i$

$$\mathrm{Var}(\hat{\mu}) = \frac{1}{n^2}\mathrm{Var}\left(\sum_i X_i\right) \underbrace{=}_{\text{indép}} \frac{1}{n^2}\sum_i \mathrm{Var}(X_i) \underbrace{=}_{\text{i.i.d.}} \frac{1}{n}\mathrm{Var}(X_i) = \frac{\mu^2}{n}, E[\hat{\mu}] = \mu$$

$$\frac{\partial}{\partial\mu}(\log L_n)(\mu) = -\frac{n}{\mu} + \frac{1}{\mu^2}\sum(X_i)$$

$$\begin{aligned} I_{n(\mu)} &= \mathrm{Var}\left(-\frac{n}{\mu} + \frac{1}{\mu^2}\sum X_i\right) \\ &= \frac{1}{\mu^4}\mathrm{Var}\left(\sum X_i\right) \\ &= \frac{n}{\mu^4}\mathrm{Var}(X_i) \end{aligned}$$

$$I_{n(\mu)} = \frac{n}{\mu^2}$$

$\hat{\mu}$ sans biais et $\mathrm{Var}(\hat{\mu}) = \frac{1}{I_{n(\mu)}}$. *Donc $\hat{\mu}$ est efficace.*

TLC: $\sqrt{n}(\hat{\mu}_n - \mu) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \mu^2) \Rightarrow \mathrm{Var}(\hat{\mu}_n) = \frac{\mu^2}{n} =$ *variance de la loi gausienne asymptotique*

$\frac{\sqrt{n}(\hat{\mu}_n - \mu)}{\mu}$ *a pour loi asymptotique $\mathcal{N}(0,1)$*

- *autre paramétrisation: $(X_1, ..., X_n)$ i.i.d. $f(x) = \theta e^{-\theta x}, x \geq 0$*

$$EX_i = \frac{1}{\theta}, \mathrm{Var}\, X_i = \frac{1}{\theta^2}$$

$$\log L_n(\theta) = n\log\theta - \theta\sum_{i=1}^n X_i$$

$$\frac{\partial}{\partial\theta}(\log L_n)(\theta) = \frac{n}{\theta} - \sum X_i \hookrightarrow \hat{\theta}^{\mathrm{MV}} = \frac{1}{\overline{X}}$$

$$\hookrightarrow I_{n(\theta)} = \mathrm{Var}\left(\frac{n}{\theta} - \sum X_i\right) = \mathrm{Var}\left(\sum X_i\right) = \frac{n}{\theta^2}$$

Remarque 7.3 – cd TD1: $n\overline{X} \sim \Gamma(n, \theta)$

$$E\left[\frac{1}{n\overline{X}}\right] = \frac{\theta}{n-1} \text{ et } \mathrm{Var}\left(\frac{1}{\left(n\overline{X}\right)^2}\right) = \frac{\theta^2}{(n-1)(n-2)}$$

◇

$$E\left[\frac{1}{\overline{X}}\right] = n\frac{\theta}{n-1}$$

$$\hookrightarrow \tilde{\theta} = \frac{n-1}{n}\hat{\theta} \text{ non biaisé}$$

$$\begin{aligned}
\mathrm{Var}\left(\tilde{\theta}\right) &= \left(\frac{n-1}{n}\right)^2 \mathrm{Var}\left(\frac{1}{\overline{X}}\right) = \frac{(n-1)^2}{n^2}\left[E\left[\frac{1}{\left(\overline{X}\right)^2}\right] - \left(E\left[\frac{1}{\overline{X}}\right]\right)^2\right] \\
&= \frac{\cancel{(n-1)^2}}{\cancel{n^2}} \times \frac{\cancel{n^2}\theta^2}{\cancel{(n-1)}(n-2)} - \frac{(n-1)^2}{n^2}\frac{n^2}{(n-1)^2}\theta^2 \\
&= \theta^2\frac{n-1}{n-2} - \theta^2 = \frac{\theta^2}{n-2} \underbrace{>}_{\text{BCR}} \frac{1}{I_{n(\theta)}} \text{ non efficace}
\end{aligned}$$

$$\sqrt{n}\left(\overline{X} - \frac{1}{\theta}\right) \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, \frac{1}{\theta^2}\right)$$

$\hat{\theta}$ est asymptotiqument efficace

$\overline{X}$ asymptotiqument normal (TLC). $g(x) = \frac{1}{x}$ sur $]0, +\infty[$, $g'(x) = -\frac{1}{x^2} \neq 0$, méthode delta:

$$\sqrt{n}\left(\frac{1}{\overline{X}} - \theta\right) \xrightarrow{\mathcal{L}} \underbrace{g'\left(\frac{1}{\theta}\right)}_{=\theta^2} \mathcal{N}\left(0, \frac{1}{\theta^2}\right) = \mathcal{N}\left(0, \frac{\theta^4}{\theta^2} = \theta^2\right)$$

◇

7.2 Pivot (asymptotique) ou statistique pivotale

Definition 7.4 – *Statistique dont la loi ne dépend pas de paramètres inconnus*

Exemple 7.5 – $X_1, ..., X_n$ *i.i.d.* Bernoulli(θ) *avec* $\theta \in]0, 1[$*:*

$$\sqrt{n}\left(\overline{X} - \theta\right) \xrightarrow[\text{TLC}]{\mathcal{L}} \mathcal{N}(0, \theta(1-\theta))$$

$$\Leftrightarrow \underbrace{\sqrt{n}\frac{\overline{X} - \theta}{\sqrt{\theta(1-\theta)}}}_{\text{pivot ou stat. pivotale}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

méthode pivotale pour IC: On estime $\sqrt{\theta(1-\theta)}$ par $\sqrt{\hat{\theta}\left(1-\hat{\theta}\right)}$ « plug-in » par le LAC $g(x) = \sqrt{x(1-x)}$ avec $x \in]0, 1[$, $\sqrt{\hat{\theta}\left(1-\hat{\theta}\right)}$ estimateur consistant de $\sqrt{\theta(1-\theta)}$

$$\sqrt{n}\frac{\hat{\theta}-\theta}{\sqrt{\hat{\theta}\big(1-\hat{\theta}\big)}} = \underbrace{\sqrt{n}\frac{\hat{\theta}-\theta}{\sqrt{\theta(1-\theta)}}}_{\underset{\text{TLC}}{\xrightarrow{\mathcal{L}}}\mathcal{N}(0,1)} \times \underbrace{\frac{\sqrt{\theta(1-\theta)}}{\sqrt{\hat{\theta}\big(1-\hat{\theta}\big)}}}_{\underset{\text{consistant}}{\xrightarrow{P}} 1}$$

◇

Exemple 7.6 – $(X_1, ..., X_n)$ *de densité* $\theta > 0$. $f_\theta(x) = \frac{3}{\theta}x^2 \exp\big(-\frac{x^3}{\theta}\big)\mathbb{1}_{x\geq 0}$

EMV?

$$\log L_n(\theta) = n(\log^3 - \log\theta) + \sum_{i=1}^{n}\log(X_i^2) - \frac{1}{\theta}\sum_{i=1}^{n}X_i^3$$

$$(\log L_n)'(\theta) = -\frac{n}{\theta} + \frac{1}{\theta^2}\sum X_i^3 \Rightarrow \hat{\theta} = \frac{\sum X_i^3}{n}$$

$$(\log L_n)''(\theta) = \frac{n}{\theta^2} - \frac{2}{\theta^3}\sum X_i^3; (\log L_n)''\big(\hat{\theta}\big) = \frac{n}{\hat{\theta}^2} - \frac{2}{\hat{\theta}^3}n\hat{\theta} = -\frac{n}{\hat{\theta}^2} < 0 + \text{unicité}$$

$\Rightarrow$ *max global*

TLC:

$$\sqrt{n}\big(\hat{\theta}_n - \theta\big) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \theta^2)$$

$$\underbrace{\Leftrightarrow}_{\text{pivot asymptotique}} \quad \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\theta} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

$$\underbrace{\Rightarrow}_{\text{Slutsky}} \quad \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\hat{\theta}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

$q_{\frac{\alpha}{2}}$ *et* $q_{1-\frac{\alpha}{2}}$ *quantiles de* $\mathcal{N}(0,1)$

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\hat{\theta}} \leq 1_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

$$P\left(q_{\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}} \leq \hat{\theta}-\theta \leq q_{1-\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}}\right) \longrightarrow 1-\alpha$$

$$P\left(\underbrace{\hat{\theta} - q_{1-\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}} \leq \theta \leq \hat{\theta} - q_{\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}}}_{\Rightarrow IC(\theta) \text{ de niveau asymptotique } (1-\alpha)}\right) \longrightarrow 1-\alpha$$

◇