Notes de Cours d'Inférence Statistique

Yehor KOROTENKO

21 March 2026

Table des matieres

1 Introduction **3**
1.1 Evaluation 3
1.2 Modèle Statistique 3
1.3 Estimateurs 3
1.4 Risque quadratique 4
1.4.1 Exemple : Modèle de Poisson 4
1.5 Consistance 5
1.5.1 Exemple : Retour au modèle de Poisson 5
1.5.2 Méthode « Plug-in » 6

2 Estimateurs **7**
2.1 Cadre paramétrique 7
2.1.1 Modèle statistique paramétrique 7
2.2 Méthode des moments 7
2.3 Rendu sur le L.A.C. 9
2.3.1 Variance empirique 10
2.4 Méthode de maximum de vraisemblance 11
2.4.1 Modèle donné 11
2.4.2 En pratique 11

3 Information de Fisher, efficacité **13**
3.1 Modèle régulier 13
3.2 Score et Information de Fisher 14
3.3 Information de Fisher et derivée seconde 16
3.4 Inégalité de Cramer - Rao 17

4 Étude asymptotique des estimateurs **19**
4.1 Convergences 19
4.2 Consistance des estimateurs 20
4.3 Normalité asymptotique 20
4.4 δ-méthode 22

5 Fonction de répartition empirique **23**
5.1 Estimation empirique 24
5.2 Inverse généralisé 24
5.3 Quantile empirique 26

6 Intervalles de confiance **27**
6.1 Définitions 27

6.2 Interprétation 27
6.3 Méthode pivotale 27

7 Compléments (avant partiel) 29
7.1 Propriétés asymptotiques d'une suite d'estimateurs $\left(\hat{\theta}_n\right)_{n\geq 1}$ 29
7.2 Pivot (asymptotique) ou statistique pivotale 31

8 Estimation dans les échnatillons gaissiens 33
8.1 Loi normale et lois dérivées 33
8.2 Loi des estimateurs empritiques 35
8.3 IC des paramètres 37
8.4 Exercice 37

9 Introduction aux tests statistiques 38
9.1 Exemple 38
9.1.1 Contrôle de qualité: industriel. 38
9.1.2 Modélisation 38
9.2 Principe d'un test 39
9.3 Risque d'erreur 39
9.4 Construction d'un test 40

Introduction

§1

1.1 Evaluation

- 0.4 CC +0.6 Examen.
- Répartition : 80% partiel, 20% Interro (prévue le 26/01).

1.2 Modèle Statistique

Definition 1.1 (Modèle Statistique) – *Un modèle statistique est un espace de probabilité $(\Omega, \mathcal{A}, \mathcal{P})$ où $\mathcal{P}$ est une famille de lois de probabilité $\{P_\theta; \theta \in \Theta\}$.*

- Si $\exists p \in \mathbb{N}^*, \Theta \subset \mathbb{R}^p$: modèle paramétrique.
- Sinon : modèle non paramétrique.

Exemple 1.2 (Familles de lois) –

- *Lois de Poisson :* $\mathcal{P} = \{P(\lambda); \lambda > 0\}$.
- *Densité régulière :* $\mathcal{P} = \{\mathbb{P}; \mathbb{P}$ dont la densité admet une dérivée seconde bornée$\}$.

◇

Definition 1.3 (Observation) – *Une observation est une variable aléatoire (v.a.) dont la loi appartient à $\{P_\theta, \theta \in \Theta\}$. Notre observation aura une structure de n-échantillons $X_1, ..., X_n$ i.i.d. (indépendants et identiquement distribués) de loi commune $\in \{P_\theta, \theta \in \Theta\}$.*

Remarque 1.4 – *$(X_1, ..., X_n)$ est de loi $P_\theta^{\otimes n}$. L'échantillon contient toute l'information sur P_θ, donc sur θ.* ◇

Definition 1.5 (Identifiabilité) – *Un modèle est identifiable si et seulement si (ssi) l'application $\theta \mapsto P_\theta$ est injective.*

1.3 Estimateurs

Hypothèse : On observe $X_1, ..., X_n$ i.i.d. de loi commune $\in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$ (modèle paramétrique identifiable). Soit θ^* la vraie valeur inconnue telle que $P_{X_i} = P_{\theta^*}$.

Definition 1.6 (Estimateur) – *Un estimateur de θ est une fonction de l'échantillon $(X_1, ..., X_n)$ mesurable et indépendante de θ (calculable à partir des données).*

Notation : $\hat{\theta} = \hat{\theta}_n = h(X_1, ..., X_n)$. C'est une variable aléatoire.
Exemples : $\hat{\theta} = \overline{X}$, $\hat{\theta} = X_1 - X_3$, etc.

Questions fondamentales :
1. Comment définir un bon estimateur ?
2. Comment construire un bon estimateur ?

1.4 Risque quadratique

Idée : En moyenne, $\hat{\theta}$ doit être proche de θ. On regarde $\mathbb{E}\left[\hat{\theta} - \theta\right]$.

Definition 1.7 (Biais) – *Le biais de $\hat{\theta}$ est défini par :*

$$B\left(\hat{\theta}, \theta\right) = \mathbb{E}\left[\hat{\theta}\right] - \theta$$

*On dit que $\hat{\theta}$ est **sans biais** si $B\left(\hat{\theta}, \theta\right) = 0$.*

Definition 1.8 (Risque quadratique / MSE) –

$$R\left(\hat{\theta}, \theta\right) = \mathbb{E}\left[\left(\hat{\theta} - \theta\right)^2\right]$$

*C'est la **Mean Squared Error (MSE)** en anglais.*

On dit que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ ssi $R\left(\hat{\theta}_1, \theta\right) \leq R\left(\hat{\theta}_2, \theta\right)$.

1.4.1 Exemple : Modèle de Poisson

Soit $X_1, ..., X_n$ de loi P_θ de Poisson, $\theta > 0$. On cherche un estimateur de $\theta = \mathbb{E}[X_i]$.

Proposons : $\hat{\theta} = \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$.

Calcul du Biais :

$$\begin{aligned}
B\left(\hat{\theta}, \theta\right) &= \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] - \theta \\
&= \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}[X_i] - \theta \quad \text{(par linéarité)} \\
&= \frac{1}{n} \cdot n \cdot \mathbb{E}[X_1] - \theta \\
&= \theta - \theta = 0
\end{aligned}$$

Donc $\mathbb{E}\left[\overline{X}\right] = \theta$, est l'estimateur sans biais.

Calcul du Risque :

$$\begin{aligned}
R(\hat{\theta},\theta) &= \mathbb{E}\left[\left(\overline{X}-\theta\right)^2\right] = \mathbb{E}\left[\left(\overline{X}-\mathbb{E}[\overline{X}]\right)^2\right] \\
&= \mathrm{Var}\left(\overline{X}\right) = \mathrm{Var}\left(\frac{1}{n}\sum X_i\right) \\
&= \frac{1}{n^2}\sum \mathrm{Var}(X_i) \quad \text{(car i.i.d)} \\
&= \frac{1}{n^2}\cdot n\cdot \mathrm{Var}(X_1) = \frac{\mathrm{Var}(X_1)}{n} = \frac{\theta}{n}
\end{aligned}$$

Theoreme 1.9 (Décomposition Biais-Variance du risque) –

$$R(\hat{\theta},\theta) = \left(B(\hat{\theta},\theta)\right)^2 + \mathrm{Var}(\hat{\theta})$$

Preuve.

$$\begin{aligned}
R(\hat{\theta},\theta) &= \mathbb{E}\left[\left(\hat{\theta}-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]+\mathbb{E}[\hat{\theta}]-\theta\right)^2\right] \\
&= \mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)^2\right] + \mathbb{E}\left[\left(\mathbb{E}[\hat{\theta}]-\theta\right)^2\right] + 2\mathbb{E}\left[\left(\hat{\theta}-\mathbb{E}[\hat{\theta}]\right)\left(\mathbb{E}[\hat{\theta}]-\theta\right)\right] \\
&= \mathrm{Var}(\hat{\theta}) + \left(B(\hat{\theta},\theta)\right)^2 + 2\left(\mathbb{E}[\hat{\theta}]-\theta\right)\underbrace{\mathbb{E}\left[\hat{\theta}-\mathbb{E}[\hat{\theta}]\right]}_{0} \\
&= \mathrm{Var}(\hat{\theta}) + B(\hat{\theta},\theta)^2
\end{aligned}$$

□

1.5 Consistance

Propriété asymptotique. On ne considère que des estimateurs consistants.

Definition 1.10 (Consistance) – *Soit $(X_1,...,X_n)$ i.i.d. de loi P_θ. Soit $\hat{\theta}_n = h(X_1,...,X_n)$. $\hat{\theta}_n$ est un estimateur consistant (ou convergent) de θ ssi :*

$$\hat{\theta}_n \underset{n\to+\infty}{\overset{\mathbb{P}}{\longrightarrow}} \theta$$

Remarque 1.11 – *$\hat{\theta}_n$ est fortement consistant ssi $\hat{\theta}_n \underset{n\to+\infty}{\overset{\text{p.s.}}{\longrightarrow}} \theta$.* ◇

1.5.1 Exemple : Retour au modèle de Poisson

$\Theta = \mathbb{R}_+^*$, $\hat{\theta}_n = \overline{X}$.

- On peut invoquer la Loi des Grands Nombres (LGN) : $\overline{X} \overset{\mathbb{P}}{\longrightarrow} \mathbb{E}[X_i] = \theta$.
- Via le risque quadratique :

$$R(\hat{\theta}_n,\theta) = \mathrm{Var}\left(\overline{X}\right) = \frac{\theta}{n} \underset{n\to+\infty}{\longrightarrow} 0$$

D'après l'inégalité de Bienaymé-Tchebychev :

$$P\Big(|\hat{\theta}_n - \theta| > \varepsilon\Big) \leq \frac{\mathbb{E}\Big[\Big(\hat{\theta}_n - \theta\Big)^2\Big]}{\varepsilon^2} = \frac{R\big(\hat{\theta}_n, \theta\big)}{\varepsilon^2} \to 0$$

1.5.2 Méthode « Plug-in »

Soit $(X_1, ..., X_n)$ i.i.d. Poisson(θ). On veut estimer $\beta = P(X_i = 0) = e^{-\theta}$.

$$\hat{\beta} = e^{-\hat{\theta}} = e^{-\overline{X}}$$

$\hat{\beta}$ est consistant pour estimer β.

Lemme 1.12 (Lemme de l'application continue) – *Si $Z_n \xrightarrow{\mathbb{P}} Z$, alors $h(Z_n) \xrightarrow{\mathbb{P}} h(Z)$ pour toute fonction continue h.* ◇

Estimateurs

§2

2.1 Cadre paramétrique

2.1.1 Modèle statistique paramétrique

On dispose d'une observation $(X_1, ..., X_n)$, un échantillon de variable aléatoire i.i.d (indépendantes, identiquement distribuées) de loi commune P appartenant à une famille de lois de probabilités paramétrée $\left\{P_{\theta, \theta \in \Theta \subset \mathbb{R}^p}\right\}$.

Remarque 2.1 – *Si $\Theta \subset$ espace de dimension infinie $\to$ modèle non-paramétré.* ◇

Estimer P c'est estimer $\theta \in \mathbb{R}^p$.

Exemple 2.2 – Bernoulli *(θ)*, Exp *(θ)*, $\mathcal{N}(\mu, \sigma^2)$, *loi de densité* $f_\theta(x) = \theta x^{\theta - 1} 1_{x \in [0,1]}$ ◇

Notation 2.3 – $E_{\theta_n}[h(X_1, ..., X_n)]$, $\Theta[h(X_1, ..., X_n)]$
Loi de $(X_1, ..., X_n) \to P_\theta^{\otimes n}$ ◇

Definition 2.4 (Estimateur) –

$$\hat{\theta} = \hat{\theta}_n = h(X_1, ..., X_n)$$

Definition 2.5 (Qualité) –

- *Risque*

$$R\left(\hat{\theta}, \theta\right) = E_\theta\left[\left(\hat{\theta} - \theta\right)^2\right]$$

- *Consistance*

$$\hat{\theta}_n \underset{n \to +\infty}{\overset{P}{\to}} \theta$$

Definition 2.6 (Modèle identifiable) –

$$\theta \to P_\theta \quad \text{injective}$$

2.2 Méthode des moments

Definition 2.7 – *On appelle* ***moment théorique*** *de la loi de X_i d'ordre k:*

$$\mu_k = E\left[X_i^k\right], \quad k \geq 1$$

Definition 2.8 – *On appelle* ***moment empirique*** *de la loi des X_i d'ordre k:*

$$\hat{\mu}_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$$

Par la loi des grands nombres $\hat{\mu}_k \underset{n\to+\infty}{\overset{P}{\longrightarrow}} \mu_k$.

La méthode des moments: si on peut écrire θ ou $g(\theta)$ paramètre d'intérêt comme une fonction des k premiers moments théoriques.

$$\theta = \mathcal{L}(\mu_1, ..., \mu_k)$$

alors l'estimateur

$$\hat{\theta} = \mathcal{L}(\hat{\mu}_1, ..., \mu_k)$$

est obtenu par la méthode.

Exemple 2.9 (Des calculs des estimateurs en utilisant la méthode des moments) –

- $X_i \sim \text{Bernoulli}(\theta)$ *à valeurs 0-1,*

$$\theta = P(X_i = 1) = E[X_i] \to \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}$$

- $X_i \sim \text{Exp}(\theta)$,, $f_\theta(x) = \theta e^{-\theta x} 1_{x\geq 0}$, $E[X] = \frac{1}{\theta} \iff \theta = \frac{1}{\mu_1}$, *par la méthode des moments,*

$$\hat{\theta} = \frac{1}{\hat{\mu}_1} = \frac{1}{\overline{X}}$$

$$\begin{aligned}
\Theta(X_i) = \frac{1}{\theta^2} &\iff \theta^2 = \frac{1}{E[X_i^2] - E[X_i]^2} \\
&\iff \theta = \frac{1}{\sqrt{\mu_2 - \mu_1^2}} \\
&\implies \hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \left(\overline{X}\right)^2}}
\end{aligned}$$

- $X_1, ..., X_n$ *i.i.d. de la loi P_θ de densité*

$$f_\theta(x) = \theta x^{\theta-1} 1_{x\in[0,1]}$$

$$E_\theta[X_i] = \theta \int_0^1 x^\theta \, \mathrm{d}x = \frac{\theta}{\theta+1}$$

Méthode des moments:

$$(\theta+1)\mu_1 = \theta \Longleftrightarrow \theta(1-\mu_1) = \mu_1 \Longleftrightarrow \theta = \frac{E[X_i]}{1-E[X_i]}$$

$$\Longrightarrow \hat{\theta}_{\mathbb{M}} = \frac{\overline{X}}{1-\overline{X}},, P_\theta\left(\overline{X}=1\right) = P_\theta(X_1 = X_2 = ... = X_n = 1) = 0$$

◇

2.3 Rendu sur le L.A.C.

(L.A.C = lemme des applications continues) $(X_n)_{n\geq 1}$ suite de variables aléatoires. Si X_n converge vers X, que peut-on dire de $g(X_n)_{n\geq 1}$? Si g continue, LAC.

- si $X_n \xrightarrow{P} X$ alors $g(X_n) \xrightarrow{P} g(X)$
- si $X_n \xrightarrow{\mathcal{L}} X$ alors $g(X_n) \xrightarrow{\mathcal{L}} g(X)$

Remarque 2.10 (Condition suffisante) –

$$D_g = \{\text{points de discontinuité de } \ g\}$$

si $P\left(X \in D_g\right) = 0$, le LAC est vrai. ◇

Exemple 2.11 –

$$g(x) = \frac{x}{1-x}$$

- *LGN:* $\overline{X} \xrightarrow{P} E[X]$
- *LAC:* $g\left(\overline{X}\right) = \hat{\theta}_n \xrightarrow[n\to+\infty]{P} g(E[X]) = \theta$

◇

LAC pour des couples de suites de variables aléatoires:

- si $(X_n, Y_n) \xrightarrow{P} (X, Y)$, alors $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$, si $g : \mathbb{R}^2 \to \mathbb{R}$ ou $\mathbb{R}^2$ continue
- si $(X_n, Y_n) \xrightarrow{\mathcal{L}} (X, Y)$, alors $g(X_n, Y_n) \xrightarrow{\mathcal{L}} g(X, Y)$

Exemple 2.12 –

$$\hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\overline{X}\right)^2}} \quad \text{consistant?}$$

LGN:

- $\overline{X} \xrightarrow{P} \mu_1$
- $\frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2$

donc

$$\begin{pmatrix} \overline{X} \\ \frac{1}{n}\sum_{i=1}^n X_i^2 \end{pmatrix} \xrightarrow{P} \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

$g(x,y) = \frac{1}{\sqrt{y-x^2}} \Longrightarrow \hat{\theta}^{\mathbb{M}}$ *constant de θ, g continue sauf en $\left\{(x,y) \in \mathbb{R}^2, y = x^2\right\}$ de mesure nulle.*

Mais c'est faux pour une converge en loi. ◇

Proposition 2.13 (Convergence de couples) –

$$\begin{pmatrix} X_n \\ Y_n \end{pmatrix} \xrightarrow{P} \begin{pmatrix} X \\ Y \end{pmatrix} \quad \text{ssi} \quad \begin{cases} X_n \xrightarrow{P} X \\ Y_n \xrightarrow{P} Y \end{cases}$$

Preuve.

- $\Longrightarrow$ alors LAC $g(x,y) = x$ continue donc $X_n \to X$ et $Y_n \to Y$
- $\Longleftarrow$ convergence du couple?

$$\forall \varepsilon > 0, P(|X_n - X| + |Y_n - Y| > \varepsilon) \leq \underbrace{P\Big(|X_n - X| > \frac{\varepsilon}{2}\Big)}_{\to 0} + \underbrace{P\Big(|Y_n - Y| > \frac{\varepsilon}{2}\Big)}_{\to 0}$$

<u>Cette réciproque est fausse pour la converge en loi!</u>

□

2.3.1 Variance empirique

Si la X_i admettent une esperance μ et une variance σ^2, on appelle variance empirique

$$\begin{aligned} \hat{\sigma}_n^2 &= \frac{1}{n}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 + \frac{1}{n}\sum_{i=1}^n \overline{X}^2 - \frac{2}{n}\sum_{i=1}^n X_i\overline{X} \\ &= \frac{1}{n}\sum_{i=1}^n X_i^2 + \overline{X}^2 - 2\overline{X}\overline{X} = \tilde{\sigma}^2 \end{aligned}$$

estimateur des moments:

$$\sigma^2 = E[X_i^2] - E[X_i]^2$$

On remplace les moments théoriques par les moments empiriques

$$\to \widetilde{\sigma^2}^{\mathbb{M}} = \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\overline{X}\right)^2$$

Consistance: $\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\overline{X}\right)^2$,

$$\begin{cases} \overline{X} \xrightarrow{P} E[X] \\ \frac{1}{n}\sum_{i=1}^n X_i^2 \xrightarrow{P} E[X^2] \end{cases} \xrightarrow{\text{cv en proba}} \begin{pmatrix} \overline{X} \\ \frac{1}{n}\sum_{i=1}^n X_i^2 \end{pmatrix} \xrightarrow{\text{LAC}} \hat{\sigma}^2 \quad \text{consistant de } \operatorname{Var}(X) = E[X^2] - E[X]^2$$

Exemple 2.14 –

- *calculer le biais de* $\hat{\sigma}_n^2$
- *calculer le risque de* $\hat{\sigma}_n^2$

◇

2.4 Méthode de maximum de vraisemblance

2.4.1 Modèle donné

$(P_\theta)_{\theta\in\Theta}$ est donné s'il existe une mesure μ (positive σ définie $\to X_i$ à valeurs dans E, $E = \cup E_n$ avec $\mu(E_n)$ finie) telle que $\forall\theta, P_\theta$ admet une densité par rapport à μ.

2.4.2 En pratique

- soit E au plus dénombrable: $\mu =$ mesure de comptage. Si $\exists, \{a_1, a_2, ...\}$ tq $\sum_{k\geq 1} P_\theta(X_i = a_k) = 1$, alors $\mu = \sum_{k\geq 1} \delta_{a_k}$ avec $\delta_a(\{a\}) = 1$ mesure de dirac.

  Exemple 2.15 – Bernoulli *(θ), $X_i = 1$, probas $\theta \to \mu = \delta_0 + \delta_1$ On écrira*

  $$f_\theta(x) = \underbrace{P_\theta(\{x\})}_{=1-\theta} - P_\theta(X_i = x) \quad \text{avec} \quad x \in \{a_1, a_2, ...\}$$

  ◇

- soit $E = \mathbb{R}^p$, alors f_θ est la densité usuelle

f_θ densité de P_θ

Definition 2.16 – *On appelle vraisemblance de l'échantillon $(X_1, ..., X_n)$ la fonction*

$$\theta \to L_n(\theta) = \prod_{i=1}^{n} f_\theta(X_i) \quad \text{(variable aléatoire)}$$

Definition 2.17 – *Un estimateur du max de vraisemblance $\hat{\theta}_{MV}$ est définie par:*

$$\forall\theta \in \Theta, L_n(\theta) \leq L_n\left(\hat{\theta}\right)$$

On travaille souvent avec la **log-vraisemblance**

$$\log L_n(\theta) = \sum_{i=1}^{n} \ln f_\theta(X_i) \quad \text{somme de variables aléatoires}$$

$$\log L_n\left(\hat{\theta}\right) = \sup_{\theta\in\Theta} \log L_n(\theta)$$

Remarque 2.18 – *$\hat{\theta}$ est une variable aléatoire*

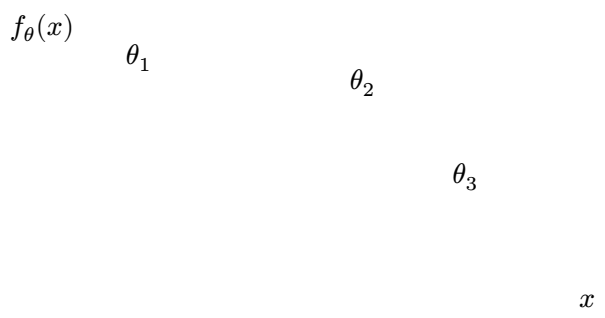

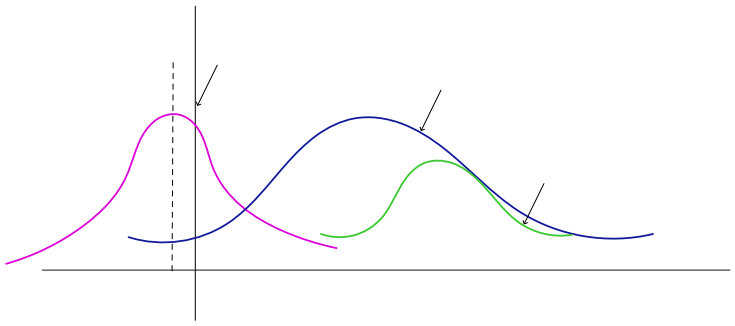

◇

fdsa

Exemple 2.19 –

- Bernoulli(θ), $f_\theta(x) = \theta^x(1-\theta)^{1-x}$, X_i *à valeurs 0-1*

$$L_n(\theta) = \prod_{i=1}^{n} \theta^{X_i}(1-\theta)^{1-X_i} = \theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}$$

$$\log L_n(\theta) = \left(\sum_{i=1}^n X_i\right)\ln\theta + \left(n - \sum_{i=1}^n X_i\right)\ln(1-\theta)$$

$$(\log L_n)'(\theta) = \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n-\sum_{i=1}^n X_i}{1-\theta} = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)}\left(\overline{X}-\theta\right)$$

Equation de vraisemblance:

$$(\log L_n)'(\theta) = 0 \iff (1-\theta)\sum_{i=1}^n X_i = \left(n - \sum_{i=1}^n X_i\right)\theta$$
$$\iff \sum_{i=1}^n X_i = n\theta \implies \theta = \frac{\sum_{i=1}^n X_i}{n}$$

le point critique, est-il un maximum?

La dérivée change de signe en $\overline{X} \to$ *on a bien un max* $\to \hat{\theta}^{MV} = \overline{X}$

Condition du 2nd ordre, si $(\log L_n)''(\theta) < 0$ *pour tout* $\theta \implies \log L_n$ *est concave* $\implies$ *max global*

$$(\log L_n)''(\theta) = -\frac{\sum_{i=1}^n X_i}{\theta^2} - \frac{n-\sum_{i=1}^n X_i}{(1-\theta)^2} < 0,, \forall\theta$$

◇

Information de Fisher, efficacité

§3

Soit $(P_\theta)_{\theta\in\Theta}$, $\Theta \subset \mathbb{R}^p$ (identifiable, donnée). On note f_θ densité de P_θ

$$\operatorname{Supp} f_\theta = \left\{x \in E,, f_{\theta(x)} > 0\right\}$$

Étant donné $(X_1, ..., X_n)$, i.i.d. de loi P_θ et $\theta \mapsto L(\theta) = \prod_{i=1}^n f_{\theta(X_i)}$ la vraisemblance de l'échantillon. Sur $\operatorname{Supp} f_\theta$ on peut calculer

$$\log L_{n(\theta)} = \sum_{i=1}^n \log f_{\theta(X_i)}$$

$$\hat{\theta} = \operatorname{argmax}_{\theta\in\Theta} \log L_{n(\theta)}$$

Proposition 3.1 – *Si $\hat{\theta}$ EMV[1] de θ, $g\left(\hat{\theta}\right)$ est un EMV de $g(\theta)$*

Objectif: que peut-on avoir de « mieux » comme estimateur? $\longrightarrow$ modèle régulier

3.1 Modèle régulier

Definition 3.2 – *Le modèle $(P_\theta)_{\theta\in\Theta}$ est dit régulier si*

1. *Θ est un ouvert et $\theta \mapsto f_{\theta(x)}$ est C^1*
2. *$\operatorname{Supp} f_\theta$ ne dépend pas de θ: $S = \left\{x,\ f_{\theta(x)} > 0\right\}$*
3. *Pour tout θ, l'application*

$$x \mapsto \frac{\frac{\partial f_\theta}{\partial \theta}(x)}{f_{\theta(x)}} \mathbb{1}_{f_{\theta(x)}>0}$$

est intégrable (L, μ) et l'intégrale

$$I(\theta) = \int_S \frac{\frac{\partial f_\theta}{\partial \theta}(x)}{f_{\theta(x)}} \mathbb{1}_{f_{\theta(x)}>0} dx$$

est continue sur Θ.

Notation 3.3 – *On note la dérivée de $f_{\theta(x)}$ par rapport à θ: $\frac{\partial f_\theta}{\partial \theta}(x)$ La quantité $I(\theta)$ est appelée* ***Information de Fisher du modèle.*** ◇

Exemple 3.4 –

- *$f_{\theta(x)} = \theta e^{-x\theta}$ densité par rapport à $\mu(dx) = \mathbb{1}_{x\geq 0} dx$*

  $\theta \mapsto \theta e^{-x\theta}$ est C^∞ sur $\Theta =]0, +\infty[$, $\operatorname{Supp} f_\theta = \mathbb{R}_+$

[1] **EMV** = Estimateur de Maximum de Vraisemblance

$$\frac{\partial f_\theta}{\partial \theta}(x) = (1 - x\theta)e^{-x\theta}$$

$$\frac{(1-x\theta)^2\left(e^{-x\theta}\right)^2}{\theta e^{-x\theta}} = \frac{(1-x\theta)^2}{\theta}e^{-x\theta}$$

$$\begin{aligned} I(\theta) &= \int_\theta^\infty \frac{(1-x\theta)^2}{\theta^2}\theta e^{-x\theta}dx \\ &= \frac{1}{\theta^2}E_\theta(1-X\theta)^2 \\ &= \frac{1}{\theta^2}[1 - 2\theta E(X) + \theta^2 E(X^2)] = \frac{1}{\theta^2} \end{aligned}$$

continue sur $]0, +\infty[$

◇

Exemple 3.5 – Bernoulli(θ), $x = 0.1$, $f_{\theta(0)} = 1 - \theta$, $f_{\theta(1)} = \theta$, *densité par rapport à* $\delta_0 + \delta_1$

Pour tout $x \in \{0, 1\}$, $\theta \mapsto f_{\theta(x)}$ *est* C^1

$$\frac{\left(\frac{\partial f_{\theta(0)}}{\partial \theta}\right)^2}{f_{\theta(0)}} = \frac{1}{1-\theta}$$

$$\frac{\left(\frac{\partial f_{\theta(1)}}{\partial \theta}\right)^2}{f_{\theta(1)}} = \frac{1}{\theta} \Rightarrow I(\theta) = \frac{1}{1-\theta} + \frac{1}{\theta} = \frac{1}{\theta(1-\theta)}$$

continue sur $]0, 1[$

◇

Exemple 3.6 – $f_{\theta(x)} = \frac{1}{\theta}\mathbb{1}_{[0,\theta]}(x) = \frac{1}{\theta}\mathbb{1}_{[x,+\infty[(\theta)}$ *modèle non régulier* ◇

3.2 Score et Information de Fisher

$(X_1, ..., X_n)$ i.i.d de loi de P_θ, f_θ

Definition 3.7 – *On appelle* ***score*** *ou* ***vecteur de score*** *la dérivée de la log vraisemblance* $\frac{\partial}{\partial\theta}\log L_{n(\theta)} = S_{n(\theta)} = \sum_{i=1}^n \frac{\partial}{\partial\theta}\log f_\theta(X_i)$

Exemple 3.8 – $X_i \sim \mathcal{E}(\theta)$, $L_{n(\theta)} = \theta^n e^{-\theta\sum_i X_i}$, $\log L_n(\theta) = n\log\theta - \theta\sum_i X_i$, *donc* $S - n(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X - i$ ◇

Remarque 3.9 –

$$E(S_n(\theta)) = E\left[n\left(\frac{1}{\theta} - \frac{\sum X_i}{n}\right)\right]$$

◇

Hyp supplémentaire de régularité: (H) pour tout estimateur $h(X)$ et tout θ, les intégrales suivantes existent et sont égales:

$$\frac{\partial}{\partial\theta}\int_S h(x)f_\theta(x)dx = \int_S h(x)\frac{\partial f_\theta}{\partial\theta}(x)dx$$

Remarque 3.10 – *condition d'application du thm de dérivation de Lebesgue.*

$$h\sup_{\tilde\theta\in V_\theta}|\frac{\partial f_\theta}{\partial\theta}(x)| \in L_1(\mu)$$

◇

Proposition 3.11 – *Sous (H), le score est centré (P_θ), $n=1$*

$$E_\theta\left[\frac{\partial}{\partial\theta}\log L_1(\theta)\right] = \int_S \frac{\partial}{\partial\theta}\log f_\theta(x)dx = \int_S \frac{\frac{\partial}{\partial\theta}f_{\theta(x)}}{\cancel{f_\theta(x)}}\cancel{f_\theta(x)}dx = \int_S \frac{\partial f_\theta}{\partial\theta}(x)dx \underbrace{=}_{(H)} \frac{\partial}{\partial\theta}\overbrace{\int f_\theta(x)dx}^{=1} = 0$$

Definition 3.12 – *L'information de Fisher associé à $(X_1,...,X_n)$*

$$I_n(\theta) \underbrace{=}_{\text{def}} E_\theta\left[\left(\frac{\partial}{\partial\theta}\log L_{n(\theta)}\right)^2\right] \overset{\text{cor. de la prop 1}}{\widehat{=}} = \mathrm{Var}_\theta\left[\frac{\partial\log L_n(\theta)}{\partial\theta}\right]$$

$$(*)E_\theta\left[\frac{\partial}{\partial\theta}\log f_\theta(X_1)\right]^2 = \int_S\left(\frac{\frac{\partial}{\partial\theta}f_\theta(x)}{f_\theta(x)}\right)^2 f_\theta(x)dx = \int_S\frac{\left(\frac{\partial}{\partial\theta}f_\theta(x)\right)^2}{f_\theta(x)} = \text{"expression de la definition 1"}$$

Exemple 3.13 – $(X_1,...,X_n)\sim\mathcal{E}(\theta)$, $\frac{\partial}{\partial\theta}\log L_n(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X_i$

$$I_n(\theta) = E\left(\left(\frac{n}{\theta} - \sum X_i\right)^2\right) = n^2E\left[\left(\frac{1}{\theta} - \frac{\sum X_i}{n}\right)^2\right] = n^2\,\mathrm{Var}\left(\overline{X}\right) = n^2\frac{1}{n}\frac{1}{\theta^2} = \frac{n}{\theta^2}$$

◇

Proposition 3.14 –

$$I_n(\theta) = nI(\theta)$$

en effet,

$$I_n(\theta) = \mathrm{Var}\left(\frac{\partial}{\partial\theta}\log L_n(\theta)\right) = \mathrm{Var}\left(\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f_\theta(X_i)\right) \underbrace{=}_{\text{independance}} = \sum_{i=1}^{n}\mathrm{Var}\left(\frac{\partial}{\partial\theta}\log f_\theta(X_i)\right) =$$
$$= n\underbrace{\mathrm{Var}\left(\frac{\partial}{\partial\theta}\log f_\theta(X_1)\right)} = nI(\theta)$$

Exemple 3.15 – $(X_1, ..., X_n)$ *i.i.d* $\mathcal{P}(\theta)$, $f_\theta(x) = e^{-\theta}\frac{\theta^x}{x!}$

$$\log L_n(\theta) = -n\theta + \left(\sum X_i\right)\log\theta - \log\prod_{i=1}^{n} X_i!$$

$$\frac{\partial}{\partial\theta}\log L_n(\theta) = -n + \frac{\sum X_i}{\theta} \Rightarrow I_n(\theta) = \mathrm{Var}\left(\frac{\sum X_i}{\theta}\right) = \frac{1}{\theta^2}n\theta = \frac{n}{\theta}$$

◇

3.3 Information de Fisher et derivée seconde

Proposition 3.16 – *En ajoutant que* $\theta \mapsto f_\theta(x)$ *est* C^2 *et que* (H) *vrai pour* $\frac{\theta^2}{\partial\theta^2}$ *alors l'info de Fisher s'écrit encore*

$$I_n(\theta) = -E_\theta\left[\frac{\partial^2\log L_n(\theta)}{\partial\theta^2}\right]$$

si $\hat{\theta}$ *EMV,* $I_{n(\hat{\theta})} > 0$

$n = 1$

$\frac{\partial^2}{\partial\theta^2}\log f_\theta(x) = \frac{\left(\frac{\partial^2 f_\theta(x)}{\partial\theta^2}\right)^2}{f_\theta(x)} - \frac{\left(\frac{\partial f_\theta}{\partial\theta}(x)\right)^2}{f_\theta^2(x)}$

$$E\left[\frac{\partial^2}{\partial\theta^2}\log f_\theta(X_1)\right] = \int_S \frac{\frac{\partial^2 f_{\theta(x)}}{\partial\theta^2}}{\cancel{f_\theta(x)}}\cancel{f_\theta(x)}dx - \underbrace{\int_S \frac{\left(\frac{\partial f_\theta(x)}{\partial}\theta\right)^2}{f_\theta^2(x)}dx}_{I(\theta)}$$

$\log L(\theta)$

$\hat{\theta}$ θ

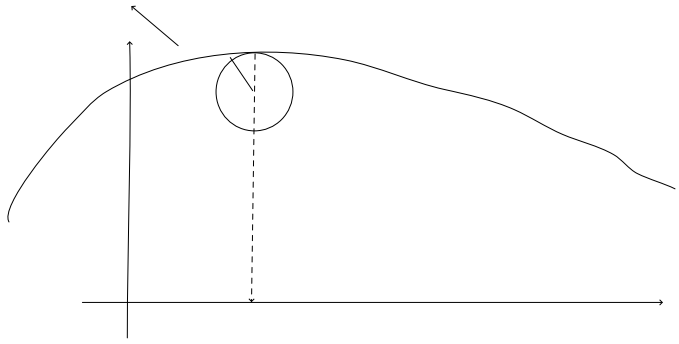

Si courbe très « piqué » en l'EMV (i.e. info. Fisher est grande) alors l'EMV est localisé de façon précise

3.4 Inégalité de Cramer - Rao

Soit $g(\theta)$ le paramètre d'intérêt où $g : \Theta \to \mathbb{R}$

Proposition 3.17 – *Sous les hypothèses d'un modèle régulier, si pour tout θ, $I(\theta) > 0$, alors pour tout estimateur $T = T(X_1, ..., X_n)$ <u>sans biais</u>, $E_\theta T^2 < +\infty$, on a*

$$\forall \theta \in \Theta, \underbrace{\mathrm{Var}_\theta(T) \geq \frac{(g'(\theta)^2)}{I_n(\theta)}} = \frac{(g'(\theta))^2}{nI(\theta)}$$

Preuve.

$$\begin{aligned}
&\forall \theta \;\; E_{\theta(T)} = g(\theta) \\
&\Rightarrow \frac{\partial}{\partial \theta} E_\theta(T) = g'(\theta) \\
T=T(X_1) \Leftrightarrow &\frac{\partial}{\partial \theta} \int_S T(x) f_\theta(x) dx = g'(\theta) \\
(H) \Leftrightarrow &\int_S T(x) \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} f_\theta(x) dx = g'(\theta) \\
\Leftrightarrow &\int_S (T(x) - g(\theta)) \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} f_\theta(x) dx = g'(\theta)
\end{aligned}$$

□

Inégalité de Cauchy-Schwarz pour $\langle h_1, h_2 \rangle = \int h_1(x) h_2(x) f_\theta(x) dx$ avec $h_1(X)$ et $h_2(X)$ centrées

$$\left(\langle T(X) - g(\theta), \frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} \rangle_\theta \right)^2 = (g'(\theta))^2 \underset{\text{c.s}}{=} \underbrace{\int (T(x) - g(\theta))^2 f_\theta(x) dx}_{= \mathrm{Var}_\theta(T)} \times \underbrace{\int \left(\frac{\frac{\partial}{\partial \theta} f_\theta(x)}{f_\theta(x)} \right)^2 f_\theta(x) dx}_{= I(\theta)}$$

Definition 3.18 – *Si T réalise l'égalité, alors T est dit* ***efficace****.*

Étude asymptotique des estimateurs

§4

Dans un moddèle paramétrique <u>régulier</u>, si $\hat{\theta}_n$ estimateur de θ, alors

$$\operatorname{Var}\left(\hat{\theta}_n\right) \geq \frac{1}{I_{n(\theta)}} = \frac{1}{nI(\theta)}$$

si $\operatorname{Var}\left(\hat{\theta}_n\right) = \frac{1}{nI(\theta)}$ sans biais, $\hat{\theta}_n$ est efficace <u>efficace</u>

Asymptotique: $n \to +\infty$,

$$n \operatorname{Var}\left(\hat{\theta}_n\right) \underset{n\to+\infty}{\longrightarrow} \frac{1}{I(\theta)}$$

4.1 Convergences

$(X_n)_{n\geq 0}$ suite de variables aléatoires réelles $\left(\mathbb{R}^d\right)$

- convergence en loi: $X_n \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} X$ ssi $P(X_n \leq x) \longrightarrow P(X \leq x)$ en tout point de continuité de x.

Lemme 4.1 (lemme de Portmanteau) – *Caractérisations équivalentes:*

- *Pour toute fonction continue bornée h,*

$$E[h(X_n)] \longrightarrow E[h(X)]$$

$\Rightarrow$ la convergence en loi est stable par passage aux fonctions continues (LAC) <u>MAIS</u> il est en général <u>faux</u> que si $X_n \overset{\mathcal{L}}{\longrightarrow} X$ et $Y_n \overset{\mathcal{L}}{\longrightarrow} Y$ alors $\binom{X_n}{Y_n} \overset{\mathcal{L}}{\longrightarrow} \binom{X}{Y}$

Cela est vrai dans 3 cas:

1. si $\begin{cases} \forall n, X_n \text{ et } Y_n \text{ sont indépendantes} \\ X \text{ et } Y \text{ sont indépendantes} \end{cases}$ alors $\begin{cases} \text{convergence en loi de } X_n \text{ et } Y_n \\ \text{convergence en loi du couple } \binom{X_n}{Y_n} \end{cases}$

2. $$\text{si } \begin{cases} X_n \overset{P}{\longrightarrow} X \\ Y_n \overset{p}{\longrightarrow} Y \end{cases} \Longrightarrow \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{P}{\longrightarrow} \begin{pmatrix} X \\ Y \end{pmatrix} \Longrightarrow \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{\mathcal{L}}{\longrightarrow} \begin{pmatrix} X \\ Y \end{pmatrix}$$

3. *(Lemme de Slutsky) (le plus important)*

$$\text{si } \begin{cases} X_n \overset{\mathcal{L}}{\longrightarrow} X \\ Y_n \overset{\mathcal{L}}{\longrightarrow} c \end{cases} \text{ alors } \begin{pmatrix} X_n \\ Y_n \end{pmatrix} \overset{\mathcal{L}}{\longrightarrow} \begin{pmatrix} X \\ c \end{pmatrix}$$

en appliquant le LAX,

$$\begin{aligned} h(x,y) &= x+y & X_n + Y_n &\xrightarrow{\mathcal{L}} X + c \\ &= xy & X_n Y_n &\xrightarrow{\mathcal{L}}\xrightarrow{\mathcal{L}} cX \\ &= \frac{x}{y} & \frac{X_n}{Y_n} &\xrightarrow{\mathcal{L}} \frac{X}{c} \end{aligned}$$

◇

4.2 Consistance des estimateurs

Definition 4.2 – *$\hat{\theta}_n$ asymptotiquement sans biais si et seulement si*

$$\text{Biais}\left(\hat{\theta}_n, \theta\right) = E\left[\hat{\theta}_n\right] - \theta \underset{n\to+\infty}{\longrightarrow} 0$$

Remarque 4.3 – *La convergence en proba n'implique pas la convergence des espérances.*

Si $X_n \xrightarrow{P} X$, $|X_n| \leq Y \in L'$, alors par convergence dominée $X_n \longrightarrow X$ dans L_1 ◇

Exemple 4.4 – $\hat{\tau}_n = \frac{1}{n}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2 = \frac{1}{n}\sum X_i^2 - \left(\overline{X}\right)^2$ *estimateur des moments de* $\tau^2 = E[X^2)] - (E[X])^2$

$$\text{Biais}(\hat{\tau}_n^2, \tau^2) = -\frac{1}{n}\tau^2 \quad \text{asymptotiqument sans biais}$$

Consistance de $\hat{\tau}_n^2$?

Outils pour montrer la consistance:

- *LGN*
- *si $R\left(\hat{\theta}_n, \theta\right) \longrightarrow 0$ alors $\hat{\theta}_n$ consistant car convergence $L^2 \Rightarrow$ convergence en probas*
- *revenir à la définition de convergence en probas*

- *si (X_i) sont i.i.d., alors (X_i^2) est i.i.d.*

$$E[X_i^2] < +\infty$$

  LGN: $\frac{1}{n}\sum_i X_i^2 \xrightarrow{P} E[X^2] = \tau^2 - \mu^2$
- $\overline{X} \xrightarrow{P} \mu$ *(LGN), LAC avec $h(x) = x^2$:* $\left(\overline{X}\right)^2 \xrightarrow{P} \mu^2$
- *Donc* $\begin{pmatrix} \frac{1}{n}\sum_{i=1}^n X_i^2 \\ \frac{1}{n}\sum X_i \end{pmatrix} \xrightarrow{P} \begin{pmatrix} \tau^2 - \mu^2 \\ \mu \end{pmatrix}$
- *LAC* $h(x,y) = x - y^2$

Donc $\frac{1}{n}\sum X_i^2 - \left(\overline{X}\right)^2 \xrightarrow{P} \tau^2 + \mu^2 - \mu^2 = \tau^2$ ◇

4.3 Normalité asymptotique

$\hat{\theta}_n$ pour θ.

→ Question: quelle est la vitesse de convergence de $\hat{\theta}_n$ vers θ ?

$(X_1, ..., X_n)$ i.i.d., d'espérance θ, $\hat{\theta} = \overline{X}$ de variance $\tau^2(\theta)$

<u>TLC</u> $\sqrt{n}\big(\overline{X} - \theta\big) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0, \tau^2(\theta))$ <u>quelle que soit la loi des</u> X_i

Definition 4.5 – *$\hat{\theta}_n$ est un estimateur <u>asymptotiquement normal</u> si et seulement si*

- *vitesse de convergence en $\sqrt{n}$*
- *convergence en loi*
- *loi limite est normale*

$$\sqrt{n}\big(\hat{\theta}_n - \theta\big) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0, \tau^2(\theta))$$

Exemple 4.6 – *$\hat{\tau}_n^2$ est-elle asymptotiqument normale ?*

$(X_1, ..., X_n)$ i.i.d. d'espérance μ, de variance τ^2

$$\hat{\tau}_n^2 = \frac{1}{n}\sum_{i=1}^{n}\big(X_i - \overline{X}\big)^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2 + \big(\overline{X} - \mu\big)^2 + \underbrace{\frac{2}{n}\sum_{i=1}^{n}(X_i - \mu)\big(\mu - \overline{X}\big)}_{=2\left(\mu - \overline{X}\right)\left(\overline{X} - \mu\right)}$$

- *TLC: si (X_i) i.i.d., alors les $(X_i - \mu)^2$ sont i.i.d. d'esperance τ^2,*

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2 - \tau^2\right) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0, u_4 - \tau^4)$$

$$\mathrm{Var}(X_i - \mu)^2 = E\Big[(X_i - \mu)^4\Big] - \mu^4 = \mu_4 - \tau^4$$

- *TLC:* $\sqrt{n}\big(\overline{X} - \mu\big) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \tau^2)$
- $\sqrt{n}(\hat{\tau}_n^2 - \tau^2) = \sqrt{n}\big(\frac{1}{n}\sum_i (X_i - \mu)^2 - \tau^2\big) - \underbrace{\sqrt{n}\big(\overline{X} - \mu\big)^2}_{\sqrt{n}\,\underbrace{\left(\overline{X} - \mu\right)}_{\xrightarrow{\mathcal{L}}\mathcal{N}(0,\tau^2)} \times \underbrace{\left(\overline{X} - \mu\right)}_{\xrightarrow{\mathcal{L},P} 0}}$

$$\left.\begin{array}{l} \overline{X} - \mu \xrightarrow{\mathcal{L}} 0 \\ \sqrt{n}\big(\overline{X} - \mu\big) \xrightarrow{\mathcal{L}} U \sim \mathcal{N}(0,1) \end{array}\right\} \overset{\text{lemme de Slutsky}}{\Longrightarrow} \sqrt{n}\big(\overline{X} - \mu\big)^2 \xrightarrow[P]{\mathcal{L}} 0$$

$$\sqrt{n}(\hat{\tau}_n^2 - \tau^2) \xrightarrow[n \to +\infty]{\mathcal{L}} Z + 0$$

Donc $\hat{\tau}_n^2$ est un estimateur asymptotiqument normal ◇

Remarque 4.7 – $\sqrt{n}\big(\hat{\theta}_n - \theta\big) \xrightarrow[n \to +\infty]{\mathcal{L}} \mathcal{N}(0, \tau^2) \Longleftrightarrow \frac{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}{\tau} \xrightarrow[n \to +\infty]{\mathcal{L}} \mathcal{N}(0,1)$ *Application du lemme de Slutsky: si $\hat{\tau}^2$ est un estimateur consistant de τ^2, alors on a encore*

$$\frac{\sqrt{n}\big(\hat{\theta}_n - \theta\big)}{\hat{\tau}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

◇

Preuve.

$$\frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\hat{\tau}} = \underbrace{\left(\sqrt{n}\frac{\big(\hat{\theta}-\theta\big)}{\tau}\right)}_{\xrightarrow{\mathcal{L}} Z\sim\mathcal{N}(0,1)} \times \underbrace{\left(\frac{\tau}{\hat{\tau}}\right)}_{\xrightarrow{P} 1}$$

$$\xrightarrow{\mathcal{L}} 1 \times Z \text{ par Slutsky et consistance de } \hat{\tau}$$

□

4.4 δ-méthode

$\hat{\theta}$ estimateur asymptotiquement normal: quelle est la loi asymptotique de $g(\theta)$?

Lemme 4.8 (méthode délta) – *Soit Z_n suite de variables aléatoires réelles t.q.*

$$\sqrt{n}(Z_n-\mu) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}\big(0,\tau^2\big)$$

Soit g une fonction dérivable, $g'(\mu) \neq 0$. Sous ces hypothèses, on a

$$\sqrt{n}[g(Z_n)-g(\mu)] \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \tilde{Z} \sim \mathcal{N}\Big(0,(g'(\mu))^2\tau^2\Big)$$

$$g(x) = g(\mu) + g'(\mu)(x-\mu) + (x-\mu)R(x-\mu) \quad \text{où} \quad R(y) \underset{y\to 0}{\to} 0$$

$$\sqrt{n}(g(Z_n)-g(\mu)) = \underbrace{g'(\mu)\underbrace{\sqrt{n}(Z_n-\mu)}_{\xrightarrow{\mathcal{L}} Z\sim\mathcal{N}(0,\tau^2)}}_{\to\mathcal{N}\left(0,(g'(\mu))^2\tau^2\right)} + \underbrace{\underbrace{\big(\sqrt{n}\big)(Z_n-\mu)}_{\xrightarrow{\mathcal{L}}\mathcal{N}(0,\tau^2)}\underbrace{R(Z_n-\mu)}_{\xrightarrow{P} 0?}}$$

A-t-on $Z_n \xrightarrow{P} \mu$?

$$\begin{aligned}
P(|X_n-\mu|>\varepsilon) &= P\left(\frac{\sqrt{n}|Z_n-\mu|}{\tau} > \frac{\sqrt{n}\varepsilon}{\tau}\right) \\
&= P\left(\frac{\sqrt{n}(Z_n-\mu)}{\tau} > \frac{\sqrt{n}\varepsilon}{\tau}\right) + P\left(\frac{\sqrt{n}(Z_n-\mu)}{\tau} < -\frac{\sqrt{n}\varepsilon}{\tau}\right) \\
&\sim= 1-\Phi_n\left(\frac{\sqrt{n}\varepsilon}{\tau}\right) + \Phi_n\left(-\frac{\sqrt{n}\varepsilon}{\tau}\right) = 2\left(1-\Phi\left(\frac{\sqrt{n}\varepsilon}{\tau}\right)\right)
\end{aligned}$$

◇

Fonction de répartition empirique

§5

$(X_1, ..., X_n)$ échantillon i.i.d. à valeurs réelles de loi F inconnue.

$$\forall x \in \mathbb{R}, F(x) = P(X_1 \leq x) = E\left[\mathbb{1}_{X_1 \leq x}\right]$$

Definition 5.1 – *La fonction de répartition <u>empirique</u> associée à $(X_1, ..., X_n)$ est définie par:*

$$\hat{F}_n : \mathbb{R} \longrightarrow [0, 1]$$
$$x \mapsto \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}$$

$\forall x \in \mathbb{R}, \hat{F}_n(x)$ est une variable aléatoire, estimateur de $F(x)$.

Definition 5.2 – *Loi empirique $P_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{X_i}$ est une loi discrète uniforme sur $\{X_1, ..., X_n\}$.*

Représentation graphique

Conditionnelement $X_1 = x_1, X_2 = x_2, ..., X_n = x_n$

$$x_{(1)} \leq x_{(2)} \leq ... \leq x_{(n)} \quad \text{valeurs ordonnées}$$

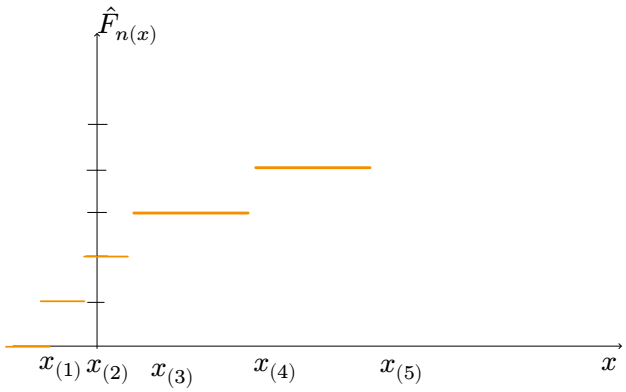

fdsa

Proposition 5.3 (Propriétés immédiats) –

- $n\hat{F}_n(x) = \sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}$ *suit la loi binomiale*$(n, F(x))$

- $R\left(\hat{F}_n(x), F(x)\right) = 0 + \frac{1}{n^2}\operatorname{Var}\left(\sum_{i=1}^n \mathbb{1}_{X_i \leq x}\right) \underbrace{=}_{\text{indep}} \frac{1}{n}F(x)(1-F(x)) \underset{n\to+\infty}{\longrightarrow} 0$ *donc* $\forall x \in \mathbb{R}, \hat{F}_n(x) \xrightarrow{P} F(x)$
- *ou bien* <u>*LGN*</u>*:* $\hat{F}_n(x)$ *estimateur* <u>*consistant*</u> *de* $F(x)$.
- *On a un résultat de convergence uniforme :*

$$\sup_{x\in\mathbb{R}}|\hat{F}_n(x) - F(x)| \underset{n\to+\infty}{\xrightarrow{P}} 0 \quad \text{(Théorème de Glivenko-Cantelli)}$$

[2]

- $\hat{F}_n(x)$ *est-il asymptotiqument normal?*

$$\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^n \mathbb{1}_{X_i \leq x}$$

TLC: les X_i *sont i.i.d., donc les* $\left\{\mathbb{1}_{X_i \leq x} = Y_i\right\}$ *sont i.i.d.*

$$\forall x, F(x) \in]0,1[, \quad \sqrt{n}\left(\hat{F}_n(x) - F(x)\right) \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \mathcal{N}(0, F(x)(1-F(x)))$$

$$\iff \frac{\hat{F}_n(x) - F(x)}{\sqrt{\frac{F(x)(1-F(x))}{n}}} \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \mathcal{N}(0,1)$$

5.1 Estimation empirique

« plug-in » ou méthode de substitution, paramètre d'intérêt $\theta = c(F)$, la méthode empirique définit $\hat{\theta}$, estimateur impirique en remplaçant F par $\hat{F}_n \to \hat{\theta}_n = c\left(\hat{F}_n\right)$.

Exemple 5.4 – $\theta = E_F(X) \to \hat{\theta}_n = E_{\hat{F}_n}(X) = \sum_{i=1}^n X_i \times \frac{1}{n} = \overline{X}$ *si* X_i *distinctes*

$$\theta = \operatorname{Var}_F(X) \to \hat{\theta}_n = \operatorname{Var}_{\hat{F}_n}(X) = \frac{1}{n}\sum\left(X_i - \overline{X}\right)^2$$

◇

5.2 Inverse généralisé

Definition 5.5 – *On définit l'inverse généralisé de* F *par:*

$$F^{-1} : [0,1] \longrightarrow \mathbb{R}$$

$$\forall \alpha \in [0,1], F^{-1}(\alpha) = \inf\{x \in \mathbb{R}, F(x) \geq \alpha\}$$

Si F *est strictement croissante,* $\inf x$ *tel que* $F(x) \geq a \Leftrightarrow x \geq F^{-1}(\alpha)$*, si* F *est la fonction d'une loi discrète.*

[2]Thm de Glivenko-Cantelli: https://fr.wikipedia.org/wiki/Th%C3%A9or%C3%A8me_de_Glivenko-Cantelli

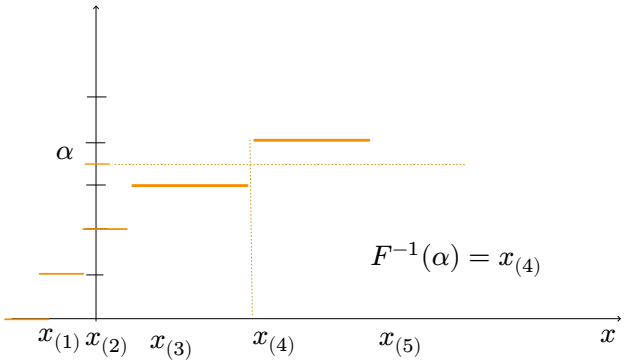

Exemple 5.6 –

$$F^{-1}(\alpha) = x \Leftrightarrow F(x) = \alpha \Leftrightarrow P(X \leq x) = \alpha \Leftrightarrow P(X > x) = 1 - \alpha$$

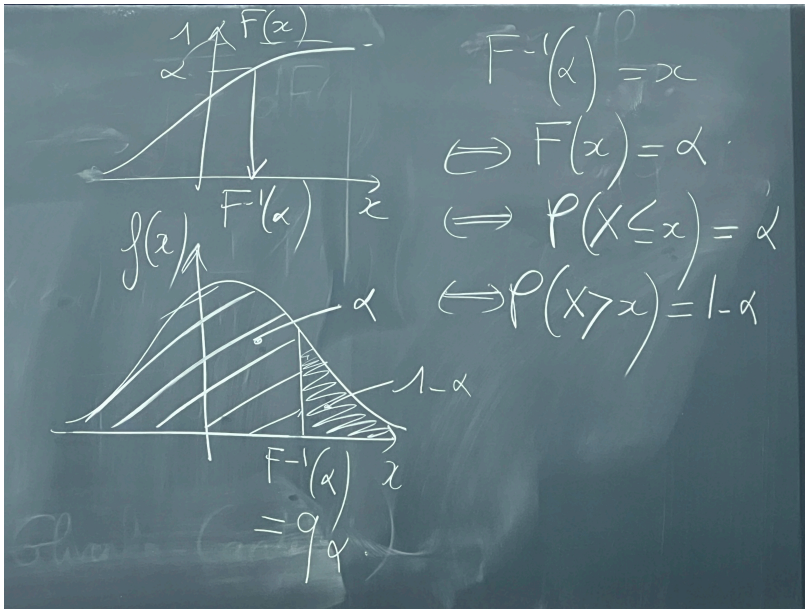

◇

Vocab:

- F^{-1} s'appelle aussi la <u>fonction quantile</u>
- $F^{-1}(\alpha)$ = quantile d'ordre α, de la loi F
- $F^{-1}\left(\frac{1}{4}\right)$ = 1er quantile
- $F^{-1}\left(\frac{1}{2}\right)$ = médiane
- $F^{-1}\left(\frac{3}{4}\right)$ = 3eme quantile

Lemme 5.7 – *U variable aléatoire sur $[0,1]$, F f.r., alors $F^{-1}(U)$ est une variable aléatoire de loi F* ◇

- Si F bijective:

$$P(F^{-1}(U) \leq x) \underbrace{=}_{F \text{ bijective}} P(U \leq F(x)) \underbrace{=}_{\text{car } P(U \leq x) = x \text{ sur } [0,1]} F(x)$$

- Si F discrète: F^{-1} inverse généralisé: $F^{-1}(y) \leq x \Leftrightarrow y \leq F(x)$

5.3 Quantile empirique

Definition 5.8 – *On définit le <u>quantile empirique</u> (sampe quantile) d'ordre α, comme étant le quantile de $\hat{F}_n$:*

$$\hat{q}_{n,\alpha} = \hat{F}_n^{-1}(\alpha) = \inf\Big\{x, \hat{F}_n(x) \geq \alpha\Big\}$$

Proposition 5.9 –

- *On peut montrer que $\hat{q}_{n,\alpha} = X_{([n\alpha])}$ où $X_{(1)} \leq X_{(2)} \leq ... \leq X_{(n)}$ est l'echantillon ordoné des $(X_i)_{1 \leq i < n}$*

$$[u] = \text{le plus petit entier} \geq u$$

Exemple 5.10 – $\alpha = \frac{1}{2}$, $\left[\frac{n}{2}\right]$,

$$\begin{cases} \text{si } n = 2k \quad \text{medianne} = \hat{q}_{n,\frac{1}{2}} = X_{(k)} \\ \text{si } n = 2k+1 \quad \text{medianne} = \hat{q}_{n,\frac{1}{2}} = X_{(k+1)} \end{cases}$$

- *Consistance*

  si $\alpha \in]0,1[$, si F est strictement croissante au voisinage de α

◇

Intervalles de confiance

§6

6.1 Définitions

$(X_1, ..., X_n)$ i.i.d. de loi $P \in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$, on s'interesse à $\theta \in \mathbb{R}$ ou $g(\theta) : \mathbb{R}^p \longrightarrow \mathbb{R}$.

Un intervalle de confiance pour θ, de niveau de confiance $1-\alpha, \alpha \in]0,1[$ est un intervalle dont les bornes sont <u>aléatoires</u>, fonctions de l'échantillon et ne dépend PAS des paramètres inconnus du modèle et tel que

$$P([B\inf(X_1, ..., X_n); B\sup(X_1, ..., X_n)] \ni \theta) \geq 1-\alpha$$

[3]

- Un IC est calculable à partir des données
- si l'inégalité est une égalité = niveau de confiance est <u>exact</u>.
- si on a $P(\theta \in [B\inf, B\sup]) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$, niveau est <u>asymptotique</u>.
- en général $\alpha = 1\%, 5\%$

6.2 Interprétation

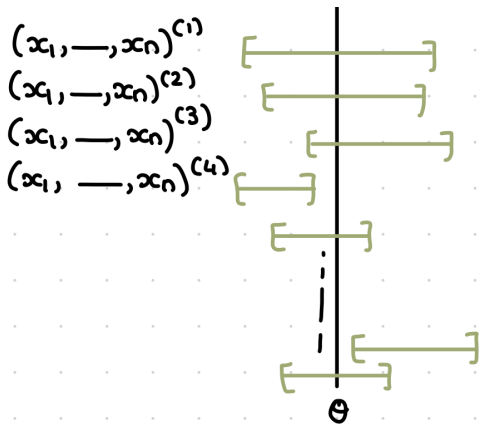

$IC = [B\inf(X_1, ..., X_n), B\sup(X_1, ..., X_n)]$ formule mathématique qui g´arantit le niveau $1-\alpha$. On observe $X_1 = x_1, X_2 = x_2, ..., X_n = x_n$, une réalisation de l'échantillon aléatoire. On calcule $IC = [2.3; 5.1]$ de niveau de confiance 95% ($\alpha = 5\%$).

En moyenne, sur 100 intervalles calculés (avec la même formule), il y a 5 intervalles qui ne contiennent pas θ.

$$P(\theta \in [B\inf, B\sup]) = 1-\alpha$$

$\cancel{P(\theta \in [2.3, 5.1]) = 95\%}$ car θ un nombre

6.3 Méthode pivotale

$(X_1, ..., X_n)$ i.i.d. d'espérance $\theta \in \mathbb{R}$, de variance $\sigma^2(\theta)$. Soit $\hat{\theta}$, asymptotiquement normal:

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0, \sigma^2(\theta))$$

$$\Leftrightarrow \frac{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}{\sigma(\theta)} \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0,1)$$

Par définition des quantiles gaussiens, $q_\alpha = \Phi^{-1}(\alpha)$ où Φ f.r. de $\mathcal{N}(0,1)$

[3] $B\inf$ pour borne inférieure et $B\sup$ pour borne supérieure

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\sigma(\theta)} \leq q_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

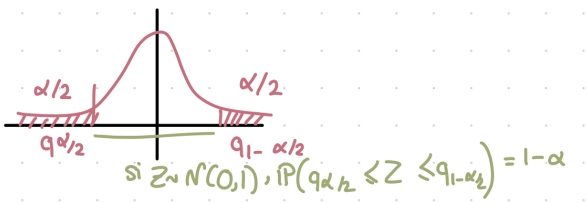

- **pivot ou statistique pivotale** $= \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\hat{\sigma}}$ statistique centrée réduite issue de $\hat{\theta}$, où $\sigma^2(\theta)$ estimé par $\hat{\sigma}^2$, <u>consistant</u> pour estimer $\sigma^2(\theta)$.

  Si c'est le cas,

$$\underbrace{\frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\sigma(\theta)}}_{\underset{\hat{\theta}\text{ as. normal}}{\overset{\mathcal{L}}{\longrightarrow}}\ \mathcal{N}(0,1)} \times \underbrace{\frac{\sigma^2(\theta)}{\hat{\sigma}^2}}_{\underset{\text{estimateur consistant}}{\overset{P}{\longrightarrow}}\ 1} \underset{n\to+\infty}{\overset{\mathcal{L}}{\longrightarrow}} \mathcal{N}(0,1) \quad \text{par lemme de Slutsky}$$

- on en déduit

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\left(\hat{\theta}-\theta\right)}{\hat{\sigma}}(\theta) \leq q_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

$$P\left(\hat{\theta}-\frac{1}{\sqrt{n}}\hat{\sigma}q_{1-\frac{\alpha}{2}} \leq \theta \leq \hat{\theta}-\frac{1}{\sqrt{n}}\hat{\sigma}q_{\frac{\alpha}{2}}\right) \longrightarrow 1-\alpha$$

Compléments (avant partiel)

§7

1. Retour sur normalité asymptotique
2. Exemple
3. Pivot asymptotique
4. Exemple 2

7.1 Propriétés asymptotiques d'une suite d'estimateurs $\left(\hat{\theta}_n\right)_{n\geq 1}$

- Consistance $\hat{\theta}_n \xrightarrow{P} \theta$
- Normalité asymptotique, s'il existe $\sigma^2 > 0$

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \underset{n\to+\infty}{\xrightarrow{\mathcal{L}}} \mathcal{N}(0, \sigma^2)$$

De façon générale, s'il existe $v_n \underset{n\to+\infty}{\longrightarrow} +\infty$

$$v_{n\left(\hat{\theta}_n - \theta\right)} \xrightarrow{\mathcal{L}} Y$$

On dit que $\hat{\theta}_n$ converge à la vitesse $\frac{1}{v_n}$

Remarque 7.1 – *Si $\hat{\theta}_n$ asymptotiqument normal $\Rightarrow$ $\hat{\theta}_n$ consistant*

$$\hat{\theta}_n - \theta = \underbrace{\frac{1}{\sqrt{n}}}_{\to 0} \underbrace{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}_{\xrightarrow{\mathcal{L}} \mathcal{N}(0,\sigma^2)} \underset{\text{Slutsky}}{\xrightarrow{\mathcal{L} \text{ ou } P}} 0$$

$$U_n = \frac{1}{\sqrt{n}} \to 0$$

◇

<u>δ-méthode</u>

$$\sqrt{n}(X_n - 1) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$
$$\sqrt{n}(X_n - 1) \overset{\mathcal{L}}{\approx} Z \sim \mathcal{N}(0, 1)$$
$$X_n \overset{\mathcal{L}}{\approx} 1 + \frac{1}{\sqrt{n}} Z$$

Si g dérivable en 1,

$$g(1 + h) = g(1) + hg(1)$$

$$g(X_n) \approx g(1) + \frac{1}{\sqrt{n}} g'(1) Z$$

$$\sqrt{n}(g(X_n) - g(1)) \approx g'(1) Z$$

<u>δ-méthode</u>

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0,1)$$

g dérivable en θ

$$g(x) = g(\theta) + g'(\theta)[(x-\theta) + r(x)] \text{ où } r(x) \underset{x\to 0}{\to} 0$$

$\hat{\theta}_n \xrightarrow{P} \theta$ donc (LAC) $r\left(\hat{\theta}_n\right) \longrightarrow r(\theta) = 0$

$$g\left(\hat{\theta}_n\right) = g(\theta) + \left(\hat{\theta}_n - \theta\right)\left[g'(\theta) + r\left(\hat{\theta}_n\right)\right]$$

$$\sqrt{n}\left(g\left(\hat{\theta}_n\right) - g(\theta)\right) = \underbrace{\sqrt{n}\left(\hat{\theta}_n - \theta\right)}_{\xrightarrow{\mathcal{L}} Z}\left[\underbrace{g'(\theta) + r\left(\hat{\theta}_n\right)}_{\xrightarrow{P} g'(\theta)}\right] \underset{\text{Slutsky}}{\Rightarrow} \sqrt{n}\left(g\left(\hat{\theta}_n\right) - g(\theta)\right) \xrightarrow{\mathcal{L}} g'(\theta)Z \sim \mathcal{N}\left(0, (g'(\theta))^2\right)$$

Exemple 7.2 – *$X_1, .., X_n$ de loi de densité $f(x) = \frac{1}{\mu}e^{-\frac{x}{\mu}}, x \geq 0, \mu = E[X_i] > 0$*
μ estimé par $\hat{\mu} = \overline{X}$ efficace? $\log L_n(\mu) = -n\log\mu - \frac{1}{\mu}\sum_{i=1}^n X_i$

$$\mathrm{Var}(\hat{\mu}) = \frac{1}{n^2}\mathrm{Var}\left(\sum_i X_i\right) \underbrace{=}_{\text{indép}} \frac{1}{n^2}\sum_i \mathrm{Var}(X_i) \underbrace{=}_{\text{i.i.d.}} \frac{1}{n}\mathrm{Var}(X_i) = \frac{\mu^2}{n}, E[\hat{\mu}] = \mu$$

$$\frac{\partial}{\partial\mu}(\log L_n)(\mu) = -\frac{n}{\mu} + \frac{1}{\mu^2}\sum(X_i)$$

$$\begin{aligned} I_{n(\mu)} &= \mathrm{Var}\left(-\frac{n}{\mu} + \frac{1}{\mu^2}\sum X_i\right) \\ &= \frac{1}{\mu^4}\mathrm{Var}\left(\sum X_i\right) \\ &= \frac{n}{\mu^4}\mathrm{Var}(X_i) \end{aligned}$$

$$I_{n(\mu)} = \frac{n}{\mu^2}$$

$\hat{\mu}$ sans biais et $\mathrm{Var}(\hat{\mu}) = \frac{1}{I_{n(\mu)}}$. *Donc $\hat{\mu}$ est efficace.*
TLC: $\sqrt{n}(\hat{\mu}_n - \mu) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \mu^2) \Rightarrow \mathrm{Var}(\hat{\mu}_n) = \frac{\mu^2}{n} =$ *variance de la loi gausienne asymptotique* $\frac{\sqrt{n}(\hat{\mu}_n - \mu)}{\mu}$ *a pour loi asymptotique* $\mathcal{N}(0,1)$

- *autre paramétrisation:* $(X_1, ..., X_n)$ *i.i.d.* $f(x) = \theta e^{-\theta x}, x \geq 0$

$$EX_i = \frac{1}{\theta}, \mathrm{Var}\, X_i = \frac{1}{\theta^2}$$

$$\log L_n(\theta) = n\log\theta - \theta\sum_{i=1}^n X_i$$

$$\frac{\partial}{\partial\theta}(\log L_n)(\theta) = \frac{n}{\theta} - \sum X_i \hookrightarrow \hat{\theta}^{\mathrm{MV}} = \frac{1}{\overline{X}}$$

$$\hookrightarrow I_{n(\theta)} = \mathrm{Var}\left(\frac{n}{\theta} - \sum X_i\right) = \mathrm{Var}\left(\sum X_i\right) = \frac{n}{\theta^2}$$

Remarque 7.3 – cd TD1: $n\overline{X} \sim \Gamma(n, \theta)$

$$E\left[\frac{1}{n\overline{X}}\right] = \frac{\theta}{n-1} \text{ et } \mathrm{Var}\left(\frac{1}{\left(n\overline{X}\right)^2}\right) = \frac{\theta^2}{(n-1)(n-2)}$$

◇

$$E\left[\frac{1}{\overline{X}}\right] = n\frac{\theta}{n-1}$$

$$\hookrightarrow \tilde{\theta} = \frac{n-1}{n}\hat{\theta} \text{ non biaisé}$$

$$\begin{aligned}
\mathrm{Var}\left(\tilde{\theta}\right) &= \left(\frac{n-1}{n}\right)^2 \mathrm{Var}\left(\frac{1}{\overline{X}}\right) = \frac{(n-1)^2}{n^2}\left[E\left[\frac{1}{\left(\overline{X}\right)^2}\right] - \left(E\left[\frac{1}{\overline{X}}\right]\right)^2\right] \\
&= \frac{\cancel{(n-1)^2}}{\cancel{n^2}} \times \frac{\cancel{n^2}\theta^2}{\cancel{(n-1)}(n-2)} - \frac{(n-1)^2}{n^2}\frac{n^2}{(n-1)^2}\theta^2 \\
&= \theta^2\frac{n-1}{n-2} - \theta^2 = \frac{\theta^2}{n-2} \underbrace{>}_{\text{BCR}} \frac{1}{I_{n(\theta)}} \text{ non efficace}
\end{aligned}$$

$$\sqrt{n}\left(\overline{X} - \frac{1}{\theta}\right) \xrightarrow{\mathcal{L}} \mathcal{N}\left(0, \frac{1}{\theta^2}\right)$$

$\hat{\theta}$ est asymptotiqument efficace

$\overline{X}$ asymptotiqument normal (TLC). $g(x) = \frac{1}{x}$ sur $]0, +\infty[$, $g'(x) = -\frac{1}{x^2} \neq 0$, méthode delta:

$$\sqrt{n}\left(\frac{1}{\overline{X}} - \theta\right) \xrightarrow{\mathcal{L}} \underbrace{g'\left(\frac{1}{\theta}\right)}_{=\theta^2} \mathcal{N}\left(0, \frac{1}{\theta^2}\right) = \mathcal{N}\left(0, \frac{\theta^4}{\theta^2} = \theta^2\right)$$

◇

7.2 Pivot (asymptotique) ou statistique pivotale

Definition 7.4 – *Statistique dont la loi ne dépend pas de paramètres inconnus*

Exemple 7.5 – $X_1, ..., X_n$ *i.i.d.* Bernoulli(θ) *avec* $\theta \in]0, 1[$*:*

$$\sqrt{n}\left(\overline{X} - \theta\right) \xrightarrow[\text{TLC}]{\mathcal{L}} \mathcal{N}(0, \theta(1-\theta))$$

$$\Leftrightarrow \underbrace{\sqrt{n}\frac{\overline{X} - \theta}{\sqrt{\theta(1-\theta)}}}_{\text{pivot ou stat. pivotale}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

méthode pivotale pour IC: On estime $\sqrt{\theta(1-\theta)}$ par $\sqrt{\hat{\theta}\left(1-\hat{\theta}\right)}$ « plug-in » par le LAC $g(x) = \sqrt{x(1-x)}$ avec $x \in]0, 1[$, $\sqrt{\hat{\theta}\left(1-\hat{\theta}\right)}$ estimateur consistant de $\sqrt{\theta(1-\theta)}$

$$\sqrt{n}\frac{\hat{\theta}-\theta}{\sqrt{\hat{\theta}\big(1-\hat{\theta}\big)}} = \underbrace{\sqrt{n}\frac{\hat{\theta}-\theta}{\sqrt{\theta(1-\theta)}}}_{\underset{\text{TLC}}{\xrightarrow{\mathcal{L}}}\mathcal{N}(0,1)} \times \underbrace{\frac{\sqrt{\theta(1-\theta)}}{\sqrt{\hat{\theta}\big(1-\hat{\theta}\big)}}}_{\underset{\text{consistant}}{\xrightarrow{P}} 1}$$

◇

Exemple 7.6 – $(X_1, ..., X_n)$ *de densité* $\theta > 0$. $f_\theta(x) = \frac{3}{\theta}x^2 \exp\big(-\frac{x^3}{\theta}\big)\mathbb{1}_{x\geq 0}$

EMV?

$$\log L_n(\theta) = n(\log^3 - \log\theta) + \sum_{i=1}^{n}\log(X_i^2) - \frac{1}{\theta}\sum_{i=1}^{n}X_i^3$$

$$(\log L_n)'(\theta) = -\frac{n}{\theta} + \frac{1}{\theta^2}\sum X_i^3 \Rightarrow \hat{\theta} = \frac{\sum X_i^3}{n}$$

$$(\log L_n)''(\theta) = \frac{n}{\theta^2} - \frac{2}{\theta^3}\sum X_i^3; (\log L_n)''\big(\hat{\theta}\big) = \frac{n}{\hat{\theta}^2} - \frac{2}{\hat{\theta}^3}n\hat{\theta} = -\frac{n}{\hat{\theta}^2} < 0 + \text{unicité}$$

$\Rightarrow$ *max global*

TLC:

$$\sqrt{n}\big(\hat{\theta}_n - \theta\big) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \theta^2)$$

$$\underbrace{\Leftrightarrow}_{\text{pivot asymptotique}} \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\theta} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

$$\underbrace{\Rightarrow}_{\text{Slutsky}} \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\hat{\theta}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$$

$q_{\frac{\alpha}{2}}$ *et* $q_{1-\frac{\alpha}{2}}$ *quantiles de* $\mathcal{N}(0,1)$

$$P\left(q_{\frac{\alpha}{2}} \leq \frac{\sqrt{n}\big(\hat{\theta}-\theta\big)}{\hat{\theta}} \leq 1_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

$$P\left(q_{\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}} \leq \hat{\theta}-\theta \leq q_{1-\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}}\right) \longrightarrow 1-\alpha$$

$$P\left(\underbrace{\hat{\theta} - q_{1-\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}} \leq \theta \leq \hat{\theta} - q_{\frac{\alpha}{2}}\frac{\hat{\theta}}{\sqrt{n}}}_{\Rightarrow IC(\theta)\text{ de niveau asymptotique }(1-\alpha)}\right) \longrightarrow 1-\alpha$$

◇

Estimation dans les échnatillons gaissiens

§8

1. Loi normale et lois dérivées
2. Loi des estimateurs empririques
3. IC des paramètres
4. Exercice

8.1 Loi normale et lois dérivées

Definition 8.1 – *Z est dite gauissienne (normale) centrée réduite si sa loi admet pour densité*

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, x \in \mathbb{R}$$

On note $Z \sim \mathcal{N}(0,1)$.

X est dite de loi normale de paramètres $\mu \in \mathbb{R}$ et $\sigma^2 > 0$ ssi

$$X = \mu + \sigma Z$$

notée

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

Autres caractérisations de la loi normale:

- par densité

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

- par la fonction génératrice des moments

$$M(t) = E\left[e^{tX}\right] = e^{t\mu + \frac{1}{2}\sigma^2 t^2}, \forall t \in \mathbb{R}$$

Remarque 8.2 –

- *$\sigma^2 = 0 \to X = \mu$ presque surement*
- *si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ et $\lambda \in \mathbb{R}$, alors $\lambda X_1 + X_2 \sim \mathcal{N}(\lambda\mu_1 + \mu_2, \lambda^2\sigma_1^2 + \sigma_2^2)$*

◇

Moments centrés: densité symétrique par rapport à μ

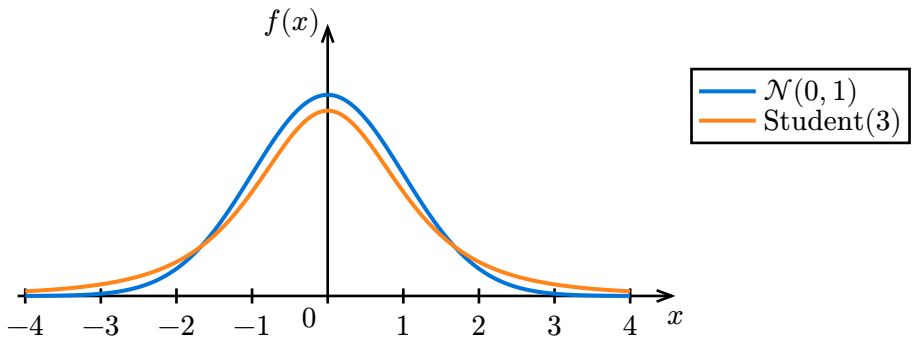

moments centrés: $E\big[(X-\mu)^k\big]$

- tous les moments centrés d'ordre impaire sont nuls
- $\mu_{2k} = \frac{(2k)!}{2^k k!}\sigma^{2k}$
  - $E\big[(X-\mu)^4\big] = 3\sigma^4$
  - $\mathrm{Var}(X) = E\big[(X-\mu)^2\big] = \sigma^2$

Definition 8.3 – *$(X_1, ..., X_d)$ échantillon i.i.d. $\mathcal{N}(0,1)$. La loi de $X_1^2 + X_2^2 + ... + X_d^2$ est appelée loi du χ^2 (chi 2) à d degrés de liberté (ddl) (degrees of freedom (df)).*

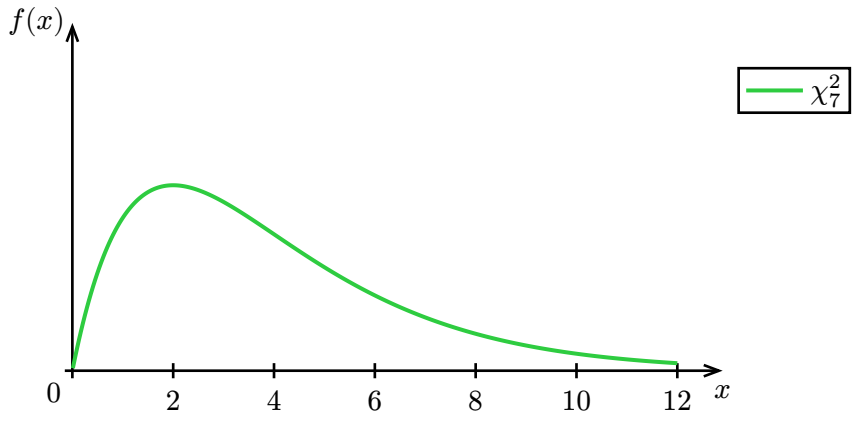

Corollaire 8.4 –

- *si Y de loi $\chi^2(d)$, $E[Y] = d$, $\mathrm{Var}(Y) = 2d$*

  $$\mathrm{Var}(X_1^2 + ... + X_d^2) \underbrace{=}_{\text{indep}} d \underbrace{\mathrm{Var}(X_i^2)}_{EX_i^h = E[X_i^2]^2 = 3-1=2}$$

- *support* $\mathbb{R}_+$
- $M(t) = (1-2t)^{-\frac{d}{2}}$, $\left(t < \frac{1}{2}\right)$

◇

Definition 8.5 – *si $X \sim \mathcal{N}(0,1)$ et $Y \sim \chi^2(d)$ indépendantes, la loi de $Z = \frac{X}{\sqrt{\frac{Y}{d}}}$ est appelée loi de Student à d ddl.*

Remarque 8.6 – *si $d \to +\infty$, la loi de Student converge vers la loi $\mathcal{N}(0,1)$*

$$\frac{Y}{d} \underset{\text{def}}{\overset{\mathcal{L}}{=}} \frac{1}{d}\sum_{i=1}^{d} U_i^2 \text{ où } U_i \sim \mathcal{N}(0,1) \text{ indép entre elles de } X$$

$$\underset{\text{LGN}}{\overset{P}{\longrightarrow}} E(U_i^2) = 1$$

donc (LAC)

$$g(x) = \sqrt{x}\frac{1}{\sqrt{\frac{Y}{d}}} \overset{P}{\longrightarrow} 1$$

par le Lemme de Slutsky $Z \overset{\mathcal{L}}{\longrightarrow} 1 \cdot X \sim \mathcal{N}(0,1)$ ◇

On introduit $(X_1, ..., X_n)$ i.i.d. $\mathcal{N}(\mu, \sigma^2)$ où μ et σ^2 paramètres inconnus.

- $\hookrightarrow \mu = E[X_i] \rightsquigarrow \hat{\mu} = \overline{X}$
- $\hookrightarrow \sigma^2 = \mathrm{Var}(X_i) \rightsquigarrow \widehat{\sigma^2} = \frac{1}{n}\sum\left(X_i - \overline{X}\right)^2$

Soit $S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X - i - \overline{X}\right)^2$ <u>non biaisé</u>

8.2 Loi des estimateurs empritiques

Theoreme 8.7 (loi de $\hat{\mu}$ et $\hat{\sigma}^2$) –

- $\overline{X}$ *et* $\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$ *sont des variables aléatoires* <u>*indépendantes*</u>
- $\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$
- $\frac{1}{\sigma^2}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2 \sim \chi^2(n-1) \Rightarrow \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$ *et* $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1)$
- $\frac{\overline{X}-\mu}{\frac{S_n}{\sqrt{n}}} \sim \mathrm{Student}(n-1)$
- $\overline{X}$ *et* $\overbrace{\left(\overline{X}, X_1 - \overline{X}, ..., X_n - \overline{X}\right)}^{T}$ *sont indépendantes*

Preuve.

$$
\begin{aligned}
M(u,t_1,...,t_n) &= E\left[e^{u\overline{X}+t_1\left(X_1-\overline{X}\right)+...+t_n\left(X_n-\overline{X}\right)}\right] \\
&= E\left[e^{\left(\frac{u}{n}+\left(\underbrace{\frac{t_1+t_2+...+t_n}{n}}_{\bar{t}}\right)\right)X_1}...e^{\left(\frac{u}{n}+\bar{t}\right)X_n}\right] \\
&= E\left[\prod_{i=1}^{n} e^{\left(\frac{u}{n}+t_i-\bar{t}\right)X_i}\right] \\
X_i \text{ indép} &= \prod_{i=1}^{n} \underbrace{E\left[e^{(u_n+t_i-\bar{t})X_i}\right]}_{M(u_n+t_i-\bar{t})} \\
&= \prod_{i=1}^{n} e^{\mu\left(\frac{u}{n}+t_i-\bar{t}\right)+\frac{\sigma^2}{2}(u_n+t_i-\bar{t})^2} \\
&= e^{\sum_{i=1}^{n}\mu\left(\frac{u}{n}+t_i-\bar{t}\right)+\frac{\sigma^2}{2}(u_n+t_i-\bar{t})^2} \\
&= e^{\mu u+\mu\overbrace{\sum_i(t_i-\bar{t})}^{0}+\frac{\sigma^2}{2}\sum_i\left(\frac{u^2}{n^2}+(t_i-\bar{t})^2+2\frac{u}{n}(t_i-\bar{t})\right)} \\
&= e^{\mu u+\frac{\sigma^2}{2}\left(\frac{u^2}{n}+\sum_i(t_i-\bar{t})^2\right)} \\
&= \underbrace{e^{\mu u+\frac{\sigma^2 u^2}{2n}}}_{M_{\overline{X}}(u)}\underbrace{e^{\frac{\sigma^2}{2}\sum_i(t_i-\bar{t})^2}}_{M_T(t_1,...,t_n)}
\end{aligned}
$$

$$
\begin{aligned}
\frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i-\mu)^2 &= \frac{1}{\sigma^2}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+\frac{n}{\sigma^2}\left(\overline{X}-\mu\right)^2+\frac{2}{\sigma^2}\sum_i\left(X_i-\overline{X}\right)\left(\overline{X}-\mu\right) \\
&= \frac{1}{\sigma^2}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+\frac{n}{\sigma^2}\left(\overline{X}-\mu\right)^2+\frac{2}{\sigma^2}\left(\overline{X}-\mu\right)\underbrace{\sum_i\left(X_i-\overline{X}\right)}_{=0} \\
&= \underbrace{\frac{1}{\sigma^2}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2}_{=\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2\sim\chi^2(n)}+\underbrace{\frac{n}{\sigma^2}\left(\overline{X}-\mu\right)^2}_{=\left(\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}\right)^2\sim\chi^2(1)}
\end{aligned}
$$

$$
\text{par indép} \Rightarrow M_{\chi^2(n)}(t) = M_?(t)M_{\chi^2(1)}(t) \Rightarrow M_?(t) = \frac{(1-2t)^{-\frac{n}{2}}}{(1-2t)^{-\frac{1}{2}}} = (1-2t)^{-\frac{(n-1)}{2}}
$$

qui caractérise la loi $\chi^2(n-1)$

$$
\frac{\overline{X}-\mu}{\frac{S_n}{\sqrt{n}}} = \frac{\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\frac{S_n}{\sqrt{n}}\times\frac{\sqrt{n}}{\sigma}} = \frac{\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{S_n^2}{\sigma^2}}}
$$

$$
\frac{S_n^2}{\sigma^2} = \left(\frac{\sum\left(X_i-\overline{X}\right)^2}{\sigma^2}\right) \sim \chi^2(n-1)
$$

donc $\overline{X}+S_n^2$ indépendantes $\underbrace{\Rightarrow}_{\text{def Student}}$ Student$(n-1)$ $\square$

8.3 IC des paramètres

Pivot. $\frac{\overline{X}-\mu}{\frac{S_n}{\sqrt{n}}} \underset{\text{loi exacte}}{\sim} \text{Student}(n-1)$

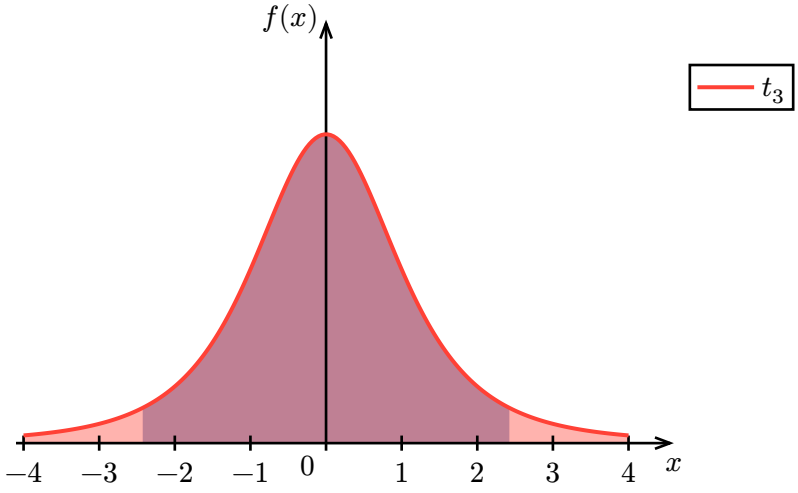

$$P\Big(q_{\frac{\alpha}{2}}t(n-1)\Big) \leq \frac{\overline{X}-\mu}{\frac{S_n}{\sqrt{n}}} \leq q_{1-\frac{\alpha}{2}}t(n-1))$$

$$\Leftrightarrow P\left(\overline{X} - \frac{S_n}{\sqrt{n}}q_{1-\frac{\alpha}{2}}t(n-1) \leq \mu \leq \overline{X} + \frac{S_n}{\sqrt{n}}q_{1-\frac{\alpha}{2}}t(n-1)\right) = 1-\alpha$$

IC (σ^2), $\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$

$$P\left(q_{\frac{\alpha}{2}}\chi^2(n-1) \leq \frac{n\hat{\sigma}^2}{\sigma^2} \leq q_{1-\frac{\alpha}{2}}\chi^2(n-1)\right) = 1-\alpha$$

$$= P\left(\frac{n\hat{\sigma}^2}{q_{1-\frac{\alpha}{2}}\chi^2(n-1)} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{q_{\frac{\alpha}{2}}\chi^2(n-1)}\right) = \alpha - 1$$

$\rightsquigarrow$ IC $= \left[\frac{n\hat{\sigma}^2}{q_{1-\frac{\alpha}{2}}\chi^2(n-1)}, \frac{n\hat{\sigma}^2}{q_{\frac{\alpha}{2}}\chi^2(n-1)}\right]$

Remarque 8.8 – $\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$ *et* $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1)$

$$\frac{\overline{X}-\mu}{\frac{S_n}{\sqrt{n}}} \sim \text{Student}(n-1)$$

◇

8.4 Exercice

- Montrez que $\left(\hat{\mu}, \widehat{\sigma^2}\right)$ sont les EMV de μ et σ^2
- $R(S_n^2, \sigma^2) > R(\widehat{\sigma_n}^2, \sigma^2)$ où R représente une risque

Introduction aux tests statistiques

§9

9.1 Exemple

9.1.1 Contrôle de qualité: industriel.

Produit des « pièces »
- ↳ de bonne qualité
- ↳ défectueuses

Pour l'industriel, on suppose acceptable une proportion de 20% de pièces déféctueuses.

Pour contrôler: prélever « au hasard » n pièces, vérifiées ($p \leq 20\%$)

9.1.2 Modélisation

$i^{\text{ème}}$ pièce $X_i = \begin{cases} 0 \text{ si bonne qualité} \\ 1 \text{ si défectueuse} \end{cases}$ $p = P(X_i = 1)$

↳ on prélève n pièces et on observe un échantillon $(X_1, ..., X_n)$ dont les valeurs obsérvées sont $(x_1, ..., x_n)$.

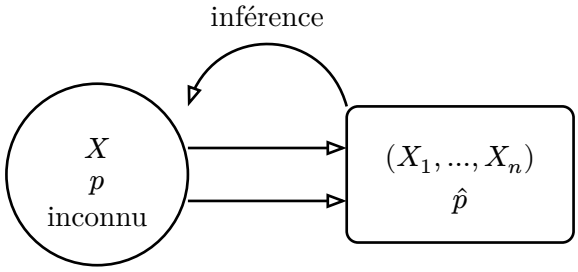

Que vaut p? → on éstime
- proportion empirique
- $X_i \underset{\text{indep}}{\sim}$ Bernouili(p) → $\hat{p} = \overline{X}$

On observe $\overline{x} = 0.22$, $n = 100$

On procède avec un intervalle de confiance pour p. On définie $\hat{p} = \overline{X}$, TLC:

$$\frac{\overline{X} - p}{\sqrt{\frac{p(1-p)}{n}}} \underset{n \to +\infty}{\xrightarrow{\mathcal{L}}} \mathcal{N}(0,1)$$

on estime l'écart-type par $\frac{\hat{p}(1-\hat{p})}{n}$ (consistant). Lemme de Slutsky:

$$\frac{\overline{X} - p}{\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}} = \frac{\overline{X} - p}{\sqrt{\frac{p(1-p)}{n}}} \times \frac{\overbrace{\underbrace{\sqrt{\frac{p(1-p)}{n}}}_{\xrightarrow{P} 1}}^{\text{LGN: } \overline{X} \xrightarrow{P} p \text{ , LAC: } g(x) = \sqrt{\frac{x(1-x)}{n}}}}{\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}} \underset{n \to +\infty}{\xrightarrow{\mathcal{L}}} 1.\mathcal{N}(0,1)$$

$$P\left(\text{qnorm}_{\frac{\alpha}{2}} \leq \frac{\overline{X}-p}{\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}} \leq \text{qnorm}_{1-\frac{\alpha}{2}}\right) \underset{n\to+\infty}{\longrightarrow} 1-\alpha$$

$$\Leftrightarrow P\left(\overline{X} - q_{1-\frac{\alpha}{2}}\sqrt{\frac{\overline{X}\left(1-\overline{X}\right)}{n}} \leq p \leq \overline{X} - q_{\frac{\alpha}{2}}\sqrt{\frac{\overline{X}\left(1-\overline{X}\right)}{n}}\right) \underset{n}{\longrightarrow} 1-\alpha$$

$\text{IC}(p) = \overline{X} \pm \text{qnorm}_{1-\frac{\alpha}{2}}\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}$ de niveau asymptotique $1-\alpha$.

ex: $\overline{x} = 0.22$, $\alpha = 5\%$, $n = 100$, $\text{IC} = [0.14, 0.30]$

Question: est-ce que $p \leq 0.2$ ou bien $p > 0.2$?

9.2 Principe d'un test

$\Theta \subset]0,1[$. On veut tester si $p \leq 0.2$ ou $p > 0.2$.

$\Theta = \underbrace{\Theta_0}_{]0,0.2]} \cup \underbrace{\Theta_1}_{]0,1[}$ sous-ensembles disjoints.

On teste H_0: $p \in \Theta_0$, $p \leq 0.2$ contre H_1: $p \in \Theta_1$, $p > 0.2$

Conclusion:
- Soit on conserve H_0: $(p \leq 0.2)$
- Soit on rejet H_0 (on conclut $p > 0.2$)

Definition 9.1 – *Un test de H_0 contre H_1 est défini par la construction d'une région de rejet de H_0, $\mathcal{R}$*
- *si $(X_1, ..., X_n) \in \mathcal{R}$, on rejette H_0 (au profit de H_1)*
- *si $(X_1, ..., X_n) \notin \mathcal{R}$, on conserve H_0*

Souvent $\mathcal{R} = \{(X_1, ..., X_n), T(X_1, ..., X_n) > c\}$
- T: statistique de test (à valeur réelle)
- c: seuil du test

Remarque 9.2 – *la décision d'un test est aléatoire (dépend de T aléatoire)* ◇

Comment relier $\mathcal{R}$ aux hypothèses testées ?

9.3 Risque d'erreur

Definition 9.3 – *Erreure de 1ère espèce ou risque de type I est la fonction définie sur*

$$\begin{aligned}\Theta_0 &\longrightarrow [0,1]\\ p &\mapsto P_p((X_1, ..., X_n) \in \mathcal{R}) = P_p(\text{on rejette } H_0)\end{aligned}$$

Le test est dit de niveaux α si

$$\sup_{p\in\Theta_0} P_p(\text{rejet de } H_0) \leq a$$

R_q erreur de premiere espece $= P(\text{rejet de } H_0 \text{ à tort})$

réalité / décision	H_0 vraie	H_1 vraie
H_0 vraie	ok	erreure de première espèce
H_1 vraie	erreure de seconde espece	ok

Definition 9.4 – *L'erreure de seconde espèce est la fonction définie sur risque de type II*

$$\Theta_1 \longrightarrow [0,1]$$
$$\beta : p \mapsto P_p((X_1, ..., X_n) \not\in \mathcal{R}) = P_p(\text{on conserve } H_0)$$

Remarque 9.5 – *erreur de sconde espèce est* $P(\text{conserver } H_0 \text{ à tort})$ ◇

puissance du test: = 1-erreur 2nde espèce

$$\prod : p \in \Theta_1 \longrightarrow P_p((X_1, ..., X_n) \in \mathcal{R})$$

Choix: les 2 erreurs ne peuvent pas être minimiser simultanément. En général α augmente quand β diminue.

Test: On choisit de contrôler l'erreur de 1ere espèce ($\Rightarrow$ l'erreur de seconde espèce est inconnue en général)

9.4 Construction d'un test

Principe: déterminer $\mathcal{R}$ tel que erreur de première espèce $\leq \alpha$ (si on a plusieurs tests, on choisira (point de vue théorique) celui dont l'erreur de seconde espèce est la plus petite (ou de puissance la plus grande)). Basé sur une dissymétrie de H_0 et H_1 dans la construction.

Exemple 9.6 – $H_0 : p \leq 0.2$ *contre* $H_1 : p > 0.2$ *(*$\overline{x} = 0.22$*)*

- *p inconnu donc on l'estime* $\hat{p} = \overline{X}$
- *idée: sous* H_1*,* $\hat{p}$ *prend de plus grandes valeurs que sous* H_0

↳ *$\mathcal{R}$ du type $\hat{p} > c$ avec c tel que $P_p(\hat{p} > c) \leq \alpha$? (calcul? loi limite du paramètre p?)*

$$\hat{p} = \overline{X} \longrightarrow \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$$

a pour loi approché $\mathcal{N}(0,1)$

$$P(\hat{p} > c) = P\left(\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} > \overbrace{c}^{=\left(\frac{c-p}{\sqrt{\frac{p(1-p)}{n}}}\right)}\right)$$

On veut que

$$\sup_{\substack{p\in\Theta_0\\ p\leq 0.2}} P\left(\frac{\hat{p}-p}{\sqrt{\frac{p(1-p)}{n}}} > c\right) \leq \alpha$$

↳ *le sup est atteint en* $p = 0.2$

$$\mathcal{R} = \left\{(X_1, ..., X_n), \frac{\hat{p}-0.2}{\sqrt{\frac{0.2(1-0.2)}{n}}} > c\right\}$$

Trouver c *tel que* $P((X_1, ..., X_n) \in \mathcal{R}) \underset{n\to+\infty}{\longrightarrow} \alpha$

$$P\left(\frac{\hat{p}-0.2}{\sqrt{\frac{0.2(1-0.2)}{n}}} > c\right) \underset{n\to+\infty}{\longrightarrow} \alpha \text{ ssi } c = \text{qnorm}_{1-\alpha}$$

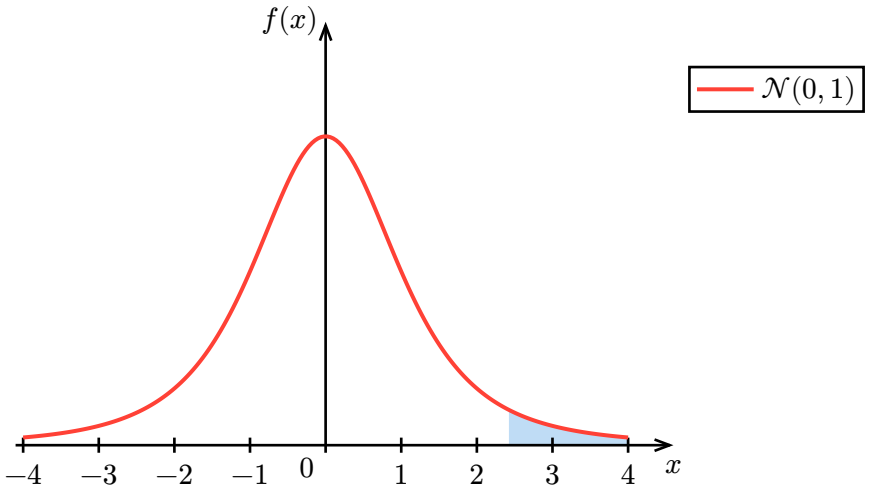

- *rejet de* H_0 *ssi*

$$T = \underbrace{\frac{\hat{p}-0.2}{\sqrt{\frac{0.2(1-0.2)}{n}}}}_{\substack{\text{statstique}\\ \text{de test}}} > \text{qnorm}_{1-\alpha}$$

A.N. $\alpha = 5\%$, $\text{qnorm}_{1-\alpha} = 1.645$, $n = 100$, $\hat{p} = \overline{x} = 0.22$

↳

$$T = \frac{\overline{x}-0.2}{\sqrt{\frac{0.2(1-0.2)}{100}}} = \frac{0.02}{\sqrt{\frac{0.2(1-0.2)}{100}}} = \frac{0.2}{\sqrt{0.2\cdot 0.8}} = \frac{0.2}{0.4} = \frac{1}{2} < 1.645$$

Conclusion: on conserve H_0 *(on ne connaît pas le risque associé)*

$$\begin{aligned}\text{rejet } H_0 &\Leftrightarrow \overline{x} > 0.2 + 1.645\sqrt{\frac{0.2(1-0.2)}{100}}\\ &\Leftrightarrow \overline{x} > 0.266\end{aligned}$$

◇