

# Notes de Inference Statistique

Yehor Korotenko

January 27, 2026



# CONTENTS

<b>1</b>	<b>Lecture 1</b>	<b>3</b>
1.1	Modèle Statistique . . . . .	3
1.2	Estimateurs . . . . .	3
1.3	Risque quadratique . . . . .	4
1.4	Consistance . . . . .	5
<b>2</b>	<b>Lecture 2</b>	<b>7</b>
2.1	Cadre paramétrique . . . . .	7
2.1.1	Modèle statistique paramétrique . . . . .	7
2.2	Méthode des moments . . . . .	7
2.3	Rendu sur le L.A.C. . . . .	8
2.3.1	Variance empirique . . . . .	9
2.4	Méthode de maximum de vraisemblance . . . . .	10
2.4.1	Modèle donné . . . . .	10
2.4.2	En pratique . . . . .	10



# CHAPTER 1

## LECTURE 1

### Evaluation

- 0.4 CC +0.6 Examen.
- Répartition : 80% partiel, 20% Interro (prévue le 26/01).

### 1.1 Modèle Statistique

**DEFINITION 1.1.1 (MODÈLE STATISTIQUE)** — Un modèle statistique est un espace de probabilité  $(\Omega, \mathcal{A}, \mathcal{P})$  où  $\mathcal{P}$  est une famille de lois de probabilité  $\{P_\theta; \theta \in \Theta\}$ .

- Si  $\exists p \in \mathbb{N}^*, \Theta \subset \mathbb{R}^p$  : modèle paramétrique.
- Sinon : modèle non paramétrique.

**EXEMPLE 1.1.2 (FAMILLES DE LOIS)** —

- Lois de Poisson :  $\mathcal{P} = \{P(\lambda); \lambda > 0\}$ .
- Densité régulière :  $\mathcal{P} = \{\mathbb{P}; \mathbb{P} \text{ dont la densité admet une dérivée seconde bornée}\}$ .

**DEFINITION 1.1.3 (OBSERVATION)** — Une observation est une variable aléatoire (v.a.) dont la loi appartient à  $\{P_\theta, \theta \in \Theta\}$ . Notre observation aura une structure de  $n$ -échantillons  $X_1, \dots, X_n$  i.i.d. (indépendants et identiquement distribués) de loi commune  $\in \{P_\theta, \theta \in \Theta\}$ .

**REMARK 1.1.4** —  $(X_1, \dots, X_n)$  est de loi  $P_\theta^{\otimes n}$ . L'échantillon contient toute l'information sur  $P_\theta$ , donc sur  $\theta$ .

**DEFINITION 1.1.5 (IDENTIFIABILITÉ)** — Un modèle est identifiable si et seulement si (ssi) l'application  $\theta \mapsto P_\theta$  est injective.

### 1.2 Estimateurs

**Hypothèse :** On observe  $X_1, \dots, X_n$  i.i.d. de loi commune  $\in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$  (modèle paramétrique identifiable). Soit  $\theta^*$  la vraie valeur inconnue telle que  $P_{X_i} = P_{\theta^*}$ .

**DEFINITION 1.2.1 (ESTIMATEUR)** — Un estimateur de  $\theta$  est une fonction de l'échantillon  $(X_1, \dots, X_n)$  mesurable et indépendante de  $\theta$  (calculable à partir des données).

**Notation :**  $\hat{\theta} = \hat{\theta}_n = h(X_1, \dots, X_n)$ . C'est une variable aléatoire.

Exemples :  $\hat{\theta} = \bar{X}$ ,  $\hat{\theta} = X_1 - X_3$ , etc.

Questions fondamentales :

1. Comment définir un bon estimateur ?
2. Comment construire un bon estimateur ?

### 1.3 Risque quadratique

**Idée :** En moyenne,  $\hat{\theta}$  doit être proche de  $\theta$ . On regarde  $\mathbb{E}[\hat{\theta} - \theta]$ .

**DEFINITION 1.3.1 (BIAS)** — Le biais de  $\hat{\theta}$  est défini par :

$$B(\hat{\theta}, \theta) = \mathbb{E}[\hat{\theta}] - \theta$$

On dit que  $\hat{\theta}$  est **sans biais** si  $B(\hat{\theta}, \theta) = 0$ .

**DEFINITION 1.3.2 (RISQUE QUADRATIQUE / MSE)** —

$$R(\hat{\theta}, \theta) = \mathbb{E}[(\hat{\theta} - \theta)^2]$$

C'est la **Mean Squared Error (MSE)** en anglais.

On dit que  $\hat{\theta}_1$  est meilleur que  $\hat{\theta}_2$  ssi  $R(\hat{\theta}_1, \theta) \leq R(\hat{\theta}_2, \theta)$ .

#### Exemple : Modèle de Poisson

Soit  $X_1, \dots, X_n$  de loi  $P_\theta$  de Poisson,  $\theta > 0$ . On cherche un estimateur de  $\theta = \mathbb{E}[X_i]$ .

Proposons :  $\hat{\theta} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ .

**Calcul du Biais :**

$$\begin{aligned} B(\hat{\theta}, \theta) &= \mathbb{E} \left[ \frac{1}{n} \sum_{i=1}^n X_i \right] - \theta \\ &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] - \theta \quad (\text{par linéarité}) \\ &= \frac{1}{n} \cdot n \cdot \mathbb{E}[X_1] - \theta \\ &= \theta - \theta = 0 \end{aligned}$$

Donc  $\mathbb{E}[\bar{X}] = \theta$ , est l'estimateur sans biais.

**Calcul du Risque :**

$$\begin{aligned} R(\hat{\theta}, \theta) &= \mathbb{E}[(\bar{X} - \theta)^2] = \mathbb{E}[(\bar{X} - \mathbb{E}[\bar{X}])^2] \\ &= \text{Var}(\bar{X}) = \text{Var} \left( \frac{1}{n} \sum_{i=1}^n X_i \right) \\ &= \frac{1}{n^2} \sum \text{Var}(X_i) \quad (\text{car i.i.d}) \\ &= \frac{1}{n^2} \cdot n \cdot \text{Var}(X_1) = \frac{\text{Var}(X_1)}{n} = \frac{\theta}{n} \end{aligned}$$

PROPOSITION 1.3.3 (DÉCOMPOSITION BIAIS-VARIANCE DU RISQUE) —

$$R(\hat{\theta}, \theta) = (B(\hat{\theta}, \theta))^2 + \text{Var}(\hat{\theta})$$

*Proof* —

$$\begin{aligned} R(\hat{\theta}, \theta) &= \mathbb{E}[(\hat{\theta} - \theta)^2] \\ &= \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}] + \mathbb{E}[\hat{\theta}] - \theta)^2] \\ &= \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2] + \mathbb{E}[(\mathbb{E}[\hat{\theta}] - \theta)^2] + 2\mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}] - \theta)] \\ &= \text{Var}(\hat{\theta}) + (B(\hat{\theta}, \theta))^2 + 2(\mathbb{E}[\hat{\theta}] - \theta) \underbrace{\mathbb{E}[\hat{\theta} - \mathbb{E}[\hat{\theta}]]}_0 \\ &= \text{Var}(\hat{\theta}) + B(\hat{\theta}, \theta)^2 \end{aligned}$$

□

## 1.4 Consistance

Propriété asymptotique. On ne considère que des estimateurs consistants.

DEFINITION 1.4.1 (CONSISTANCE) — Soit  $(X_1, \dots, X_n)$  i.i.d. de loi  $P_\theta$ . Soit  $\hat{\theta}_n = h(X_1, \dots, X_n)$ .  $\hat{\theta}_n$  est un estimateur consistant (ou convergent) de  $\theta$  ssi :

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \theta$$

REMARK 1.4.2 —  $\hat{\theta}_n$  est fortement consistant ssi  $\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{p.s.} \theta$ .

### Exemple : Retour au modèle de Poisson

$$\Theta = \mathbb{R}_+^*, \hat{\theta}_n = \bar{X}.$$

- On peut invoquer la Loi des Grands Nombres (LGN) :  $\bar{X} \xrightarrow{\mathbb{P}} \mathbb{E}[X_i] = \theta$ .
- Via le risque quadratique :

$$R(\hat{\theta}_n, \theta) = \text{Var}(\bar{X}) = \frac{\theta}{n} \xrightarrow{n \rightarrow +\infty} 0$$

D'après l'inégalité de Bienaymé-Tchebychev :

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \leq \frac{\mathbb{E}[(\hat{\theta}_n - \theta)^2]}{\varepsilon^2} = \frac{R(\hat{\theta}_n, \theta)}{\varepsilon^2} \rightarrow 0$$

### Méthode "Plug-in"

Soit  $(X_1, \dots, X_n)$  i.i.d. Poisson( $\theta$ ). On veut estimer  $\beta = P(X_i = 0) = e^{-\theta}$ .

$$\hat{\beta} = e^{-\hat{\theta}} = e^{-\bar{X}}$$

$\hat{\beta}$  est consistant pour estimer  $\beta$ .

LEMMA 1.4.3 (LEMME DE L'APPLICATION CONTINUE) — Si  $Z_n \xrightarrow{\mathbb{P}} Z$ , alors  $h(Z_n) \xrightarrow{\mathbb{P}} h(Z)$  pour toute fonction continue  $h$ .





# CHAPTER 2

## LECTURE 2

### 2.1 Cadre paramétrique

#### 2.1.1 Modèle statistique paramétrique

On dispose d'une observation  $(X_1, \dots, X_n)$ , un échantillon de variable aléatoire i.i.d (indépendantes, identiquement distribuées) de loi commune  $P$  appartenant à une famille de lois de probabilités paramétrée  $\{P_{\theta}, \theta \in \Theta \subset \mathbb{R}^p\}$ .

**REMARK 2.1.1** — Si  $\Theta \subset$  espace de dimension infinie  $\rightarrow$  modèle non-paramétré.

Estimer  $P$  c'est estimer  $\theta \in \mathbb{R}^p$

**EXAMPLE 2.1.2** — Bernolli( $\theta$ ), Exponentielle( $\theta$ ),  $\mathcal{N}(\mu, \sigma^2)$ , loi de densité  $f_{\theta}(x) = \theta x^{\theta-1} 1_{x \in [0,1]}$

**Notation.**  $E_{\theta_n}[h(X_1, \dots, X_n)], Var_{\theta}[h(X_1, \dots, X_n)]$   
Loi de  $(X_1, \dots, X_n) \rightarrow P_{\theta}^{\otimes n}$

**DEFINITION 2.1.3 (ESTIMATEUR)** —

$$\hat{\theta} = \hat{\theta}_n = h(X_1, \dots, X_n)$$

**DEFINITION 2.1.4 (QUALITÉ)** — • Risque

$$R(\hat{\theta}, \theta) = E_{\theta}[(\hat{\theta} - \theta)^2]$$

• Consistance

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{P} \theta$$

**DEFINITION 2.1.5 (MODÈLE IDENTIFIABLE)** —

$$\theta \rightarrow P_{\theta} \text{ injective}$$

### 2.2 Méthode des moments

**DEFINITION 2.2.1** — On appelle **moment théorique** de la loi de  $X_i$  d'ordre  $k$ :

$$\mu_k = E[X_i^k], \quad k \geq 1$$

**DEFINITION 2.2.2** — On appelle **moment empirique** de la loi des  $X_i$  d'ordre  $k$ :

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Par la loi des grands nombres  $\hat{\mu}_k \xrightarrow[n \rightarrow +\infty]{P} \mu_k$

La méthode des moments: si on peut écrire  $\theta$  ou  $g(\theta)$  paramètre d'intérêt comme une fonction des  $k$  premiers moments théoriques.

$$\theta = \mathcal{L}(\mu_1, \dots, \mu_k)$$

alors l'estimateur

$$\hat{\theta} = \mathcal{L}(\hat{\mu}_1, \dots, \mu_k)$$

est obtenu par la méthode.

**EXAMPLE 2.2.3** — Des calculs des estimateurs en utilisant la méthode des moments.

- $X_i \sim \text{Bernoulli}(\theta)$  à valeurs 0-1,  $\theta = P(X_i = 1) = E[X_i] \rightarrow \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$
- $X_i \sim \text{Exp}(\theta)$ ,  $f_\theta(x) = \theta e^{-\theta x} 1_{x \geq 0}$ ,  $E[X] = \frac{1}{\theta} \Leftrightarrow \theta = \frac{1}{\mu_1}$ , par la méthode des moments,

$$\hat{\theta} = \frac{1}{\hat{\mu}_1} = \frac{1}{\bar{X}}$$

$$\begin{aligned} \text{Var}_\theta(X_i) = \frac{1}{\theta^2} \Leftrightarrow \theta^2 &= \frac{1}{E[X_i^2] - E[X_i]^2} \\ \Leftrightarrow \theta &= \frac{1}{\sqrt{\mu_2 - \mu_1^2}} \Rightarrow \hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2}} \end{aligned}$$

- $X_1, \dots, X_n$  i.i.d. de la loi  $P_\theta$  de densité

$$f_\theta(x) = \theta x^{\theta-1} 1_{x \in [0,1]}$$

$$E_\theta[X_i] = \theta \int_0^1 x^\theta dx = \frac{\theta}{\theta+1}$$

Méthode des moments:

$$\begin{aligned} (\theta+1)\mu_1 &= \theta \Leftrightarrow \theta(1-\mu_1) = \mu_1 \Leftrightarrow \theta = \frac{E[X_i]}{1-E[X_i]} \\ \Rightarrow \hat{\theta}_{MM} &= \frac{\bar{X}}{1-\bar{X}}, P_\theta(\bar{X}=1) = P_\theta(X_1 = X_2 = \dots = X_n = 1) = 0 \end{aligned}$$

## 2.3 Rendu sur le L.A.C.

(L.A.C = lemme des applications continues)  $(X_n)_{n \geq 1}$  suite de variables aléatoires. Si  $X_n$  converge vers  $X$ , que peut-on dire de  $g(X_n)_{n \geq 1}$ ? Si  $g$  continue, LAC.

- si  $X_n \xrightarrow{P} X$  alors  $g(X_n) \xrightarrow{P} g(X)$
- si  $X_n \xrightarrow{\mathcal{L}} X$  alors  $g(X_n) \xrightarrow{\mathcal{L}} g(X)$

**REMARK 2.3.1 (CONDITION SUFFISANTE)** —

$$D_g = \{\text{points de discontinuité de } g\}$$

si  $P(X \in D_g) = 0$ , le LAC est vrai.

## EXAMPLE 2.3.2 —

$$g(x) = \frac{x}{1-x}$$

$$\text{LGN: } \bar{X} \xrightarrow{P} E[X]$$

$$\bullet \text{ LAC: } g(\bar{X}) = \hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{P} g(E[X]) = \theta$$

LAC pour des couples de suites de variables aléatoires:

- si  $(X_n, Y_n) \xrightarrow{P} (X, Y)$ , alors  $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$ , si  $g : \mathbb{R}^2 \rightarrow \mathbb{R}$  ou  $\mathbb{R}^2$  continue
- si  $(X_n, Y_n) \xrightarrow{L} (X, Y)$ , alors  $g(X_n, Y_n) \xrightarrow{L} g(X, Y)$

## EXAMPLE 2.3.3 —

$$\hat{\theta}_2 = \frac{1}{\sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2}} \quad \text{constant?}$$

LGN:

- $\bar{X} \xrightarrow{P} \mu_1$
- $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} \mu_2$

donc

$$\left[ \begin{array}{c} \bar{X} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 \end{array} \right] \xrightarrow{P} \left[ \begin{array}{c} \mu_1 \\ \mu_2 \end{array} \right]$$

$$g(x, y) = \frac{1}{\sqrt{y-x^2}} \Rightarrow \hat{\theta}^{MM} \text{ constant de } \theta, g \text{ continue sauf en } \{(x, y) \in \mathbb{R}^2, y = x^2\} \text{ de mesure nulle.}$$

Mais c'est faux pour une converge en loi.

## PROPOSITION 2.3.4 (CONVERGENCE DE COUPLES) —

$$\begin{pmatrix} X_n \\ Y_n \end{pmatrix} \xrightarrow{P} \begin{pmatrix} X \\ Y \end{pmatrix} \text{ ssi } \begin{cases} X_n \xrightarrow{P} X \\ Y_n \xrightarrow{P} Y \end{cases}$$

*Proof* —  $\bullet \Rightarrow$  alors LAC  $g(x, y) = x$  continue donc  $X_n \rightarrow X$  et  $Y_n \rightarrow Y$

- $\Leftarrow$  convergence du couple?

$$\forall \varepsilon > 0, P(|X_n - X| + |Y_n - Y| > \varepsilon) \leq \underbrace{P(|X_n - X| > \frac{\varepsilon}{2})}_{\rightarrow 0} + \underbrace{P(|Y_n - Y| > \frac{\varepsilon}{2})}_{\rightarrow 0}$$

Cette réciproque est fausse pour la converge en loi!

□

## 2.3.1 Variance empirique

Si la  $X_i$  admettent une esperance  $\mu$  et une variance  $\sigma^2$ , on appelle variance empirique

$$\begin{aligned} \hat{\sigma}_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 + \frac{1}{n} \sum_{i=1}^n \bar{X}^2 - \frac{2}{n} \sum_{i=1}^n X_i \bar{X} \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 + \bar{X}^2 - 2\bar{X}\bar{X} = \tilde{\sigma}^2 \end{aligned}$$

estimateur des moments:

$$\sigma^2 = E[X_i^2] - E[X_i]^2$$

On remplace les moments théoriques par les moments empiriques

$$\rightarrow \hat{\sigma}^{2MM} = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2$$

Consistance:  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2$ ,

$$\left\{ \begin{array}{l} \bar{X} \xrightarrow{P} E[X] \\ \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E[X^2] \end{array} \right. \xrightarrow{\text{cv en proba}} \left( \frac{\bar{X}}{\frac{1}{n} \sum_{i=1}^n X_i^2} \right) \xrightarrow{LAC} \hat{\sigma}^2 \text{ consistant de } Var(X) = E[X^2] - E[X]^2$$

**Exercice 2.3.1.** • calculer le biais de  $\hat{\sigma}_n^2$

- calculer le risque de  $\hat{\sigma}_n^2$

## 2.4 Méthode de maximum de vraisemblance

### 2.4.1 Modèle donné

$(P_\theta)_{\theta \in \Theta}$  est donné s'il existe une mesure  $\mu$  (positive  $\sigma$  définie  $\rightarrow X_i$  à valeurs dans  $E$ ,  $E = \cup E_n$  avec  $\mu(E_n)$  finie) telle que  $\forall \theta, P_\theta$  admet une densité par rapport à  $\mu$ .

### 2.4.2 En pratique

- soit  $E$  au plus dénombrable:  $\mu$  = mesure de comptage. Si  $\exists \{a_1, a_2, \dots\}$  tq  $\sum_{k \geq 1} P_\theta(X_i = a_k) = 1$ , alors  $\mu = \sum_{k \geq 1} \delta_{a_k}$  avec  $\delta_a(\{a\}) = 1$  mesure de dirac.

**EXAMPLE 2.4.1** — Bernoulli( $\theta$ ),  $X_i = 1$ , probas  $\theta \rightarrow \mu = \delta_0 + \delta_1$  On écrira

$$f_\theta(x) = \overset{=1-\theta}{P_\theta(\{x\})} - P_\theta(X_i = x) \text{ avec } x \in \{a_1, a_2, \dots\}$$

- soit  $E = \mathbb{R}^p$ , alors  $f_\theta$  est la densité usuelle

$f_\theta$  densité de  $P_\theta$

**DEFINITION 2.4.2** — On appelle vraisemblance de l'échantillon  $(X_1, \dots, X_n)$  la fonction

$$\theta \rightarrow L_n(\theta) = \prod_{i=1}^n f_\theta(X_i) \text{ (variable aléatoire)}$$

**DEFINITION 2.4.3** — Un estimateur du max de vraisemblance  $\hat{\theta}_{MV}$  est définie par:

$$\forall \theta \in \Theta, L_n(\theta) \leq L_n(\hat{\theta})$$

On travaille souvent avec la **log-vraisemblance**

$$\log L_n(\theta) = \sum_{i=1}^n \ln f_\theta(X_i) \text{ somme de variables aléatoires}$$

$$\log L_n(\hat{\theta}) = \sup_{\theta \in \Theta} \log L_n(\theta)$$

REMARK 2.4.4 —  $\hat{\theta}$  est une variable aléatoire




Figure 2.1: remarque-max-vraisemblance-1

EXAMPLE 2.4.5 — • Bernoulli( $\theta$ ),  $f_\theta(x) = \theta^x(1-\theta)^{1-x}$ ,  $X_i$  à valeurs 0-1

$$L_n(\theta) = \prod_{i=1}^n \theta^{X_i} (1-\theta)^{1-X_i} = \theta^{\sum_{i=1}^n X_i} (1-\theta)^{n-\sum_{i=1}^n X_i}$$

$$\log L_n(\theta) = \left(\sum_{i=1}^n X_i\right) \ln \theta + \left(n - \sum_{i=1}^n X_i\right) \ln(1-\theta)$$

$$(\log L_n)'(\theta) = \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n - \sum_{i=1}^n X_i}{1-\theta} = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)} (\bar{X} - \theta)$$

Equation de vraisemblance:

$$(\log L_n)'(\theta) = 0 \Leftrightarrow (1-\theta) \sum_{i=1}^n X_i = (n - \sum_{i=1}^n X_i) \theta \Leftrightarrow \sum_{i=1}^n X_i = n\theta \Rightarrow \theta = \frac{\sum_{i=1}^n X_i}{n}$$

le point critique, est-il un maximum?

- La dérivée change de signe en  $\bar{X} \rightarrow$  on a bien un max  $\rightarrow \hat{\theta}^{MV} = \bar{X}$
- Condition du 2nd ordre, si  $(\log L_n)''(\theta) < 0$  pour tout  $\theta \Rightarrow \log L_n$  est concave  $\Rightarrow$  max global

$$(\log L_n)''(\theta) = -\frac{\sum_{i=1}^n X_i}{\theta^2} - \frac{n - \sum_{i=1}^n X_i}{(1-\theta)^2} < 0, \forall \theta$$